

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación




Deep Learning


Redes Neuronales Convolucionales (CNN)

¿Necesitamos redes distintas para datos visuales?


Tal como vimos anteriormente, los MLP fracasan catastróficamente en conjuntos de datos visuales más difíciles que MNIST.

Label	Description	Examples
0	T-Shirt/Top	
1	Trouser	
2	Pullover	
3	Dress	
4	Coat	
5	Sandals	
6	Shirt	
7	Sneaker	
8	Bag	
9	Ankle boots	

¿Por qué pasa esto?



Un primero culpable es la excesiva (ridícula) cantidad de parámetros




- Imagen de 256×256
- Capa densa de 256 neuronas
- 16.777.216 parámetros

Cada neurona ve todo simultáneamente, ¿es esto adecuado para las imágenes?


Veamos un poco qué pasa en la corteza visual de los mamíferos

Areas V1 – V5

(A) Medial view of functional areas



(B) Lateral view of functional areas




V1 = Primary visual cortex
V2–V5 = Extrastriate cortex


¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. ????


Areas V1 – V5



Patrones de estímulo son detectados por células (neuronas) específicas, altamente localizadas




Neuronas se organizan de manera **jerárquica**, aumentando el nivel de **abstracción** de los patrones detectados




¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. Aprendizaje de *features* locales

Areas V1 – V5




¿Cómo podemos entonces capturar esta información estructural?



- Neuronas capaces de barrer la entrada proveen una reducción significativa en el número de parámetros (no depende de la conectividad)
- Además, dado su tamaño, permiten capturar patrones locales en cualquier posición.

Convoluciones al rescate

- Un patrón local puede ocurrir en cualquier parte de la imagen, pero las neuronas tradicionales no permiten capturar eso.
- La convolución entrega una solución a este problema, al modelar filtros (neuronas) locales que son aplicadas en toda la imagen.
- Salida de una neurona ahora entrega un mapa (antes era un número), que indica dónde se podría encontrar la *feature* capturada por la neurona.




Al ser un operador lineal, la convolución calza perfectamente con el esquema de aprendizaje de una red neuronal (productos matriciales)

¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. Aprendizaje de *features* locales


Areas V1 – V5




Uniendo todo esto, llegamos a una nueva arquitectura de red

Redes convolucionales son las redes profundas más exitosas/reconocidas/comunes

- Están formadas (generalmente) por capas convolucionales, de *pooling* y *fully connected* (MLP).
- Sustituyen la mayoría de las capas densas (*fully connected*) de los MLP, por capas convolucionales.
- Disminuyen drásticamente el número de parámetros, en comparación con los MLP.
- Sustentadas en bases biológicas.







- car
- truck
- airplane
- ship
- horse

Convolution Layer

32x32x3 image



5x5x3 filter



Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”


$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1,y-n_2]$$



elementwise multiplication and sum of
a filter and the signal (image)

Convolution Layer

32x32x3 image



Filters always extend the full depth of the input volume

5x5x3 filter




Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”


$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1,y-n_2]$$

↑
elementwise multiplication and sum of
a filter and the signal (image)

Convolution Layer




Convolution Layer




Convolution Layer


consider a second, **green** filter




For example, if we had 6 5x5 filters, we'll get 6 separate activation maps:



We stack these up to get a “new image” of size 28x28x6!







- car
- truck
- airplane
- ship
- horse

Pooling layer

- makes the representations smaller and more manageable
- operates over each activation map independently:




MAX POOLING



Fully Connected Layer (FC layer)

- Contains neurons that connect to the entire input volume, as in ordinary Neural Networks



Vamos a Colab...




Taller: más CNN en CIFAR10

Parte 1

- Tome el ejemplo disponible en el sitio del curso y juegue con los hiperparámetros y estructura de la red hasta obtener el rendimiento más alto en el set de validación/test.




Revisemos como se **ve** todo esto en la práctica



<https://poloclub.github.io/cnn-explainer/>

Revisemos como se **ve** todo esto en la práctica




https://adamharley.com/nn_vis/



one filter =>
one activation map


example 5x5 filters
(32 total)

Activations:



Preview

*[From recent Yann
LeCun slides]*




Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

Veamos un caso de estudio

ImageNet Classification with Deep Convolutional Neural Networks

A. Krizhevsky, I. Sutskever, and G. E. Hinton (NeurIPS 2012)



1958 Perceptron

1974 Backpropagation

Handwritten Recognition

1998



General Object
Detection

2008

No more funds
awkward silence (AI Winter)


1969

Perceptron criticized



1995

SVM reigns




2005

Human
Detection




2012

Deep Learning
Rises



Éxito se debe a tres elementos centrales





Yoshua Bengio




Geoffrey Hinton



Yann LeCun

Desarrollaron la parte técnica de Deep Learning en Canadá, mientras el resto del mundo se dedicaba a otros temas


Éxito se debe a tres elementos centrales




ImageNet: la primera base de datos visual práctica de gran escala

- La base para la gran mayoría de los trabajos iniciales redes convolucionales para reconocimiento visual utiliza ImageNet.
- Más de 15M de imágenes divididas en 22K categorías.
- Imágenes están relacionadas por una estructura de grafo, que captura relaciones entre ellas.
- Fueron recolectadas de la web y rotuladas utilizando Amazon Mechanical Turk.

IMAGENET



Éxito se debe a tres elementos centrales



Uso de aceleradores es una necesidad

- Volumen de datos y cómputo descarta el uso de arquitecturas tradicionales.




Uso de aceleradores es una necesidad

- Volumen de datos y cómputo descarta el uso de arquitecturas tradicionales.
- Arquitecturas distribuidas y paralelas son la solución: clusters con arreglos de GPUs.



AlexNet fue uno de los primeros ejemplos exitosos de ConvNets





- Además de utilizar redes convoluciones, introdujo una serie de “trucos” muy útiles para el entrenamiento de redes.
- Sin embargo, el gran diferenciador fue el ser capaz de aprender efectivamente de un set de datos órdenes de magnitud mayor que los existentes hasta ese momento.

Comencemos con los datos


- Para realizar el entrenamiento, se utiliza un subconjunto de ImageNet, conocido como ILSVRC-XXXX (donde XXXX es el año).
- 1K categorías, 1.2M de imágenes de entrenamiento (1.2K por categoría).
- 50K imágenes de validación y 150K de test.
- Imágenes RGB de distintas resoluciones, pero escaladas a 256x256 para esta aplicación.
- Métricas de error top-1 y top-5.

IMAGENET





Input: $224 \times 224 \times 3 = 150528$ pixels



● Layer 1:

- nFilters = 96, Size = 11×11 , Depth = 3.
- nParams (weights) = $96 \times 11 \times 11 \times 3 = 34848$.
- Stride = 4, max-pooling = $3 \times 3:1$, nNeurons (outputs) = $55 \times 55 \times 96 = 290400$.
(obs: they use 3 zero-padding, then $(227 - 11)/4 + 1 = 55$)

● Layer 2:

- nFilters=256, Size = 5×5 , Depth = 96.
- nParams = $256 \times 5 \times 5 \times 96 = 614400$.
- Stride=1, max-pooling = $3 \times 3:2$, nNeurons= $27 \times 27 \times 256 = 186624$.

● Layer 3:


- nFilters = 384, Size = 3×3 , Depth = 256.
- nParams = $384 \times 3 \times 3 \times 256 = 884736$.
- Stride=1, max-pooling = none, nNeurons = $13 \times 13 \times 384 = 64896$.

● Layer 4:

- nFilters= 384, Size= 3×3 , Depth= 384.
- nParams = $384 \times 3 \times 3 \times 384 = 1327104$.
- Stride=1, max-pooling = none, nNeurons= $13 \times 13 \times 384 = 64896$.

● Layer 5:

- nFilters = 256, Size= 3×3 , Depth= 384.
- nParams = $256 \times 3 \times 3 \times 384 = 884736$.
- Stride=1, max-pooling = $3 \times 3:2$, nNeurons= $13 \times 13 \times 256 = 43264$.



- Layer 6: Fully connected to previous layer

- nParams = $6 \times 6 \times 256 \times 4096 = 37.748.736$.
- nNeurons = 4096.


- Layer 7 : Fully connected to previous layer

- nParams = $4096 \times 4096 = 16.777.216$.
- nNeurons = 4096.

- Layer 8: Fully connected to previous layer


- nParams = $4096 \times 1000 = 4.096.000$.
- nNeurons = 1000.

AlexNet fue entrenada utilizando “solo” 2 GPUs



- Entrenada utilizando SGD en dos Nvidia GTX 580 con 3GB de VRAM durante una semana.
- Algunos números aproximados para cuantificar el tamaño:
 - $\approx 650K$ neuronas
 - $\approx 60M$ de parámetros
 - $\approx 630M$ de conexiones


Un aspecto central de su éxito fue el uso de **ReLU**



- AlexNet fue uno de los primeros trabajos en cambiar las no linealidades clásicas por ReLU.
- Esto permitió que el entrenamiento fuera varias veces más rápido.


¿Cómo controlar el sobreajuste en redes con gran cantidad de parámetros?

- Capas densas del final son igualmente propensas a sobreajustarse.
- Para evitar esto, se introdujo en 2012 una técnica llamada **Dropout**, aplicada a las capas densas.
- **Dropout** “apaga” aleatoriamente neuronas en estas capas durante el entrenamiento.
- El efecto neto es que las neuronas no pueden “confiar” en las otras, por lo que aprenden representaciones más robustas.




Regularization: **Dropout**

“randomly set some neurons to zero in the forward pass”



(a) Standard Neural Net




(b) After applying dropout.

[Srivastava et al., 2014]


Waaaait a second...

How could this possibly be a good idea?



Waaaaait a second...

How could this possibly be a good idea?




Forces the network to have a redundant representation.



Waaaaait a second...

How could this possibly be a good idea?



Another interpretation:


Dropout is training a large ensemble of models (that share parameters).

Each binary mask is one model, gets trained on only ~one datapoint.

Continuemos con los datos

- Si bien el set de datos es grande, el tamaño de la red obliga a aumentarlo aún más.
- Para esto se utilizaron técnicas de aumento de datos
- Por cada imagen se tomaron 5 subimágenes de 224x224 (4 esquinas y centro).
- Este proceso también se repite para el reflejo de cada imagen.
- Con esto, lograron aumentar 10 veces el tamaño efectivo del set de datos.
- Finalmente, a cada imagen se le resta la media de cada canal de color

IMAGENET






Aumento de datos puede verse como otro tipo de regularización

T




Aumento de datos puede verse como otro tipo de regularización


T



Aumento de datos puede verse como otro tipo de regularización




La combinación de todo esto generó resultados sorprendentes para la época




- Error top-5: 15.3%
- Error top-1: 26.2%
- Error humano: aprox. 8%


La combinación de todo esto generó resultados sorprendentes para la época




La combinación de todo esto generó resultados sorprendentes para la época



La combinación de todo esto generó resultados sorprendentes para la época



La combinación de todo esto generó resultados sorprendentes para la época



Rendimiento ha continuado mejorando



(a) Siberian husky



(b) Eskimo dog

- En la actualidad, las arquitecturas para reconocimiento visual son bastante más profundas (cientos de capas).
- Mejores métodos tienen alrededor de 89% top-1 y 99% top-5.
- Algunas muestras con código pueden verse en <https://paperswithcode.com/sota/image-classification-on-imagenet>

Taller: más CNN en CIFAR10

Parte 2

- ~~• Tome el ejemplo disponible en el sitio del curso y juegue con los hiperparámetros y estructura de la red hasta obtener el rendimiento más alto en el set de validación/test.~~
- A continuación, explore el uso de Dropout¹ y aumento de datos² sobre la arquitectura del ítem anterior y compare el efecto que estos tienen sobre los resultados.



¹ https://keras.io/api/layers/regularization_layers/dropout/

² https://www.tensorflow.org/tutorials/images/data_augmentation

Cuáles son los conceptos centrales de esta clase

- Redes convoluciones (en 2012) permitieron resolver problemas que tenían los MLP gracias a el uso de convoluciones (y otros detalles más).
- El aspecto central de las CNN es el aprendizaje de features locales en un esquema composicional jerárquico profundo.
- Si bien no son un modelo de la corteza visual, evidencia biológica valida el esquema de construcción de las CNN.
- Simplicidad y buenos resultados han llevado a estas redes a ser las más utilizadas.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



Deep Learning

Redes Neuronales Convolucionales (CNN)