

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



Deep Learning

Modelos de lenguaje

Ariel Reyes
Dpto. Ciencia de la Computación

¿Cómo podemos codificar lenguaje?

Very good drama although it appeared to have a few blank areas leaving the viewers to fill in the action for themselves. I can imagine life being this way for someone who can neither read nor write. This film simply smacked of the real world: the wife who is suddenly the sole supporter, the live-in relatives and their quarrels, the troubled child who gets knocked up and then, typically, drops out of school, a jackass husband who takes the nest egg and buys beer with it. 2 thumbs up... very very very good movie.




('the', 8),
(',', 5),
('very', 4),
('.', 4),
('who', 4),
('and', 3),
('good', 2),
('it', 2),
('to', 2),
('a', 2),
('for', 2),
('can', 2),
('this', 2),
('of', 2),
('drama', 1),
('although', 1),
('appeared', 1),
('have', 1),
('few', 1),
('blank', 1)
.....

¿Qué problemas tiene esta codificación?

- No considera el **orden** de los elementos (letras, palabras, etc.)
- No genera un **espacio semántico**: vectores cercanos no son necesariamente semánticamente similares
- Nuestro primer enfoque intentará solucionar esto utilizando **representaciones continuas y muchos datos**

Modelos de lenguaje



Modelos de lenguaje


Can you please come **here** ?




History

Word being predicted

Modelos de lenguaje neuronales




Modelos de lenguaje neuronales




Modelos de lenguaje neuronales


Típicamente las palabras son representadas mediante una codificación *one-hot*



Modelos de lenguaje neuronales




Modelos de lenguaje neuronales



Modelos de lenguaje neuronales


Labeled training instance (x,y):

x: I love to eat
y: Pizzas



Al terminar el entrenamiento, el producto esencial es la *matriz de embedding*

- La matriz de *embedding* entrega para cada palabra del vocabulario una representación vectorial.
- Esta representación es buena para clasificar (entrenamiento conjunto), y además captura un espacio semántico para las palabras.
- Esto es consecuencia directa de la representación elegida: palabras similares en sentido (o función) tienen representaciones similares.
- Las técnicas de *word embedding* más populares son *word2vec* y *Glove*.




El espacio de *word embeddings* genera “vecindades semánticas”,
donde palabras conceptualmente similares son cercanas

FRANCE	JESUS	XBOX	REDDISH	SCRATCHED	MEGABITS
AUSTRIA	GOD	AMIGA	GREENISH	NAILED	OCTETS
BELGIUM	SATI	PLAYSTATION	BLUISH	SMASHED	MB/S
GERMANY	CHRIST	MSX	PINKISH	PUNCHED	BIT/S
ITALY	SATAN	IPOD	PURPLISH	POPPED	BAUD
GREECE	KALI	SEGA	BROWNISH	CRIMPED	CARATS
SWEDEN	INDRA	PSNUMBER	GREYISH	SCRAPED	KBIT/S
NORWAY	VISHNU	HD	GRAYISH	SCREWED	MEGAHERTZ
EUROPE	ANANDA	DREAMCAST	WHITISH	SECTIONED	MEGAPIXELS
HUNGARY	PARVATI	GEFORCE	SILVERY	SLASHED	GBIT/S
SWITZERLAND	GRACE	CAPCOM	YELLOWISH	RIPPED	AMPERES


El espacio de *word embeddings* captura relaciones a través de *operaciones vectoriales*

Czech + currency	Vietnam + capital	German + airlines	Russian + river	French + actress
koruna	Hanoi	airline Lufthansa	Moscow	Juliette Binoche
Check crown	Ho Chi Minh City	carrier Lufthansa	Volga River	Vanessa Paradis
Polish zolty	Viet Nam	flag carrier Lufthansa	upriver	Charlotte Gainsbourg
CTK	Vietnamese	Lufthansa	Russia	Cecile De

El espacio de *word embeddings* captura relaciones a través de *operaciones vectoriales*



El espacio de *word embeddings* captura relaciones a través de *operaciones vectoriales*



Woman – Man $\approx$ Aunt - Uncle
King - Male + Female $\approx$ Queen
Human - Animal $\approx$ Ethics

Vamos a Colab...



¿Cómo podríamos mejorar esta codificación?

- Al no considerar explícitamente la información secuencial, la matriz de *embedding* genera codificaciones para palabras, pero no para frases.
- Para codificar una frase, se requiere un paso extra, como sumar o promediar las representaciones.
- Nuestro segundo enfoque intentará solucionar esto al **considerar explícitamente y de manera conjunta el orden de las palabras tanto en la codificación como la decodificación.**


Modelos *seq2seq* al rescate

- Con el fin de capturar más información contextual, los modelos *seq2seq* utilizan redes recurrentes para entrada y salida.
- En general, todos utilizan una arquitectura *encoder-decoder*:
 - Una red recurrente codificadora (*encoder*) procesa la secuencia de entrada y genera una representación vectorial (*estado oculto*) que captura la información relevante.
 - Una red recurrente decodificadora (*decoder*) utiliza esta representación para generar una salida adecuada.
- *Ambas redes* se entrenan de manera *conjunta* en este esquema, permitiendo capturar *información contextual* más rica.
- Este esquema es completamente general, lo que lo hace aplicable a cualquier tipo de secuencia.


Modelos **seq2seq** al rescate



Modelos **seq2seq** al rescate




Modelos seq2seq al rescate




- Al usar una **representación latente/oculta intermedia**, las secuencias de entrada y salida pueden tener largos distintos.
- Esto nos entrega la intuición que esta representación **codifica la información relevante** de la entrada.
- Además, al usar **secuencias**, esta representación considera el **orden** de las palabras, a diferencia de BoW.

El modelo más simple considera un *encoder* que genera un único vector contextual *C*




El modelo más simple considera un *encoder* que genera un único vector contextual **C**




El vector de contexto es un vector de estado oculto como cualquier otro


El modelo más simple considera un *encoder* que genera un único vector contextual **C**



Generalmente, la entrada no son las palabras en sí (o sus representación de BoW), sino que los *embeddings* de cada una de estas

El modelo más simple considera un *encoder* que genera un único vector contextual C





1 Encoder RNN

$$h_t = \sigma(W_{xh}x_t + W_{hh}h_{t-1})$$

2 Decoder RNN

if ($t > 1$)

$$y_t = \sigma(W_{ry}r_t + W_{yy}y_{t-1})$$

$$r_t = \sigma(W_{rr}r_{t-1})$$

if ($t = 1$)


$$y_1 = \sigma(W_{ry}r_1)$$

$$r_1 = \sigma(W_{rr}C)$$

$$C = \sigma(W_{hc}h_T)$$

Neural Machine Translation

SEQUENCE TO SEQUENCE MODEL




Je

suis


étudiant

Si lo pensamos bien, el esquema anterior es muy similar al generador de *captions* que vimos anteriormente




La principal diferencia es que el codificador es acá una CNN. Así, podemos ver este sistema como un traductor del “*lenguaje*” visual al escrito.

También es posible utilizar modelos con configuraciones más complejas





Veamos un ejemplo real: traducción de texto automática (Sutskever et al., 2014)

- Basado en modelo *encoder-decoder*. Ambos son implementados con *LSTM* de 4 capas.
- El vector de contexto entregado al *decoder* es el último estado oculto del *encoder*.
- Para terminar una secuencia, se utiliza el símbolo especial *<EOS>*.
- Durante el entrenamiento, los valores reales de la traducción son utilizados como entrada al *decoder*. En “producción”, se utilizan los *outputs del paso anterior*.



Veamos un ejemplo real: traducción de texto automática (Sutskever et al., 2014)



Al graficar en 2D (PCA) el vector de contexto para distintas frases, vemos que este **captura información semántica** y que además es **sensible al orden** de las palabras.

Veamos un ejemplo real: traducción de texto automática (Sutskever et al., 2014)


Type	Sentence
Our model	Ulrich UNK , membre du conseil d' administration du constructeur automobile Audi , affirme qu' il s' agit d' une pratique courante depuis des années pour que les téléphones portables puissent être collectés avant les réunions du conseil d' administration afin qu' ils ne soient pas utilisés comme appareils d' écoute à distance .
Truth	Ulrich Hackenberg , membre du conseil d' administration du constructeur automobile Audi , déclare que la collecte des téléphones portables avant les réunions du conseil , afin qu' ils ne puissent pas être utilisés comme appareils d' écoute à distance , est une pratique courante depuis des années .
Our model	“ Les téléphones cellulaires , qui sont vraiment une question , non seulement parce qu' ils pourraient potentiellement causer des interférences avec les appareils de navigation , mais nous savons , selon la FCC , qu' ils pourraient interférer avec les tours de téléphone cellulaire lorsqu' ils sont dans l' air ” , dit UNK .
Truth	“ Les téléphones portables sont véritablement un problème , non seulement parce qu' ils pourraient éventuellement créer des interférences avec les instruments de navigation , mais parce que nous savons , d' après la FCC , qu' ils pourraient perturber les antennes-relais de téléphonie mobile s' ils sont utilisés à bord ” , a déclaré Rosenker .
Our model	Avec la crémation , il y a un “ sentiment de violence contre le corps d' un être cher ” , qui sera “ réduit à une pile de cendres ” en très peu de temps au lieu d' un processus de décomposition “ qui accompagnera les étapes du deuil ” .
Truth	Il y a , avec la crémation , “ une violence faite au corps aimé ” , qui va être “ réduit à un tas de cendres ” en très peu de temps , et non après un processus de décomposition , qui “ accompagnerait les phases du deuil ” .

Vamos a Colab...




¿Debe ser único o estático el contexto?

- Si bien estos modelos son poderosos, dependen completamente de que el contexto esté bien representado en **C**, ya que es la única conexión entre *encoder* y *decoder*.
- Más aún, asumen que todos los pasos pueden basarse en el **mismo contexto**. El problema de esto es que un **contexto fijo** le da una **importancia fija** a cada parte de la **entrada**.



Una posible solución es generar contextos adaptativos, poniendo *atención* a distintas partes de la entrada


- Un mecanismo de *atención* es esencialmente una nueva *capa*, que pondera, en cada paso, la *relevancia* de cada *estado* del *encoder*, y, por consiguiente, de la secuencia de entrada.
- Esto permite reducir la carga de conocimiento que debe almacenar el vector *C* y *especializarlo* de acuerdo al paso particular del proceso.



Veamos un ejemplo simple

Neural Machine Translation

SEQUENCE TO SEQUENCE MODEL WITH ATTENTION



Je

suis

étudiant

Veamos un ejemplo simple

Time step: 7


Neural Machine Translation


SEQUENCE TO SEQUENCE MODEL WITH ATTENTION





Veamos un ejemplo simple


Entrada: El auto rojo de Carlos está averiado - **Salida:** Carlos's red car is not working






























Veamos la operatoria desde un punto de vista vectorial


Attention at time step 4




Veamos la operatoria desde un punto de vista vectorial



Veamos la operatoria desde un punto de vista vectorial




Mapa de atención muestra gráficamente el proceso



Y la pregunta del millón es: ¿cómo se obtienen los pesos de la atención?

- Un esquema muy popular fue propuesto en 2015 por Bahdanau et al.



Y la pregunta del millón es: ¿cómo se obtienen los pesos de la atención?

- En este modelo, el **contexto adaptativo** es utilizado para guiar todo el proceso:

$$y_t = \sigma(W_{yy}y_{t-1} + W_{sy}s_t + W_{cy}C_t)$$


$$s_t = \sigma(W_{ss}s_{t-1} + W_{cs}C_t)$$

$$C_t = \sum_{i=1}^T \alpha_{t,i} \langle \vec{h}_i, \overleftarrow{h}_i \rangle$$

- La **atención** es capturada por los pesos $\alpha_{t,j}$, que codifican la **relevancia** de cada **estado** oculto del **encoder**:


$$\hat{\alpha}_{tj} = V_c^T \sigma(W_c s_{t-1} + U_c h_j)$$

$$\alpha_{t,j} = \frac{\hat{\alpha}_{t,j}}{\sum_k \hat{\alpha}_{t,k}}$$




Y la pregunta del millón es: ¿cómo se obtienen los pesos de la atención?

- Al ser calculados mediante operaciones típicas de redes neuronales, la atención es **diferenciable**, por lo que se puede estimar mediante **SGD**.
- Este tipo de mecanismo de atención es conocido como **soft-attention** y es el más utilizado en modelos seq2seq.



Veamos un primer ejemplo: resumen de documentos (See y Manning, 2017)



Veamos un primer ejemplo: resumen de documentos (See y Manning, 2017)

Article (truncated): andy murray came close to giving himself some extra preparation time for his wedding next week before ensuring that he still has unfinished tennis business to attend to . the world no 4 is into the semi-finals of the miami open , but not before getting a scare from 21 year-old austrian dominic *thiem* , who pushed him to 4-4 in the second set before going down 3-6 6-4 , 6-1 in an hour and three quarters . murray was awaiting the winner from the last eight match between tomas berdych and argentina 's juan monaco . prior to this tournament *thiem* lost in the second round of a challenger event to soon-to-be new brit *aljaz* bedene . andy murray pumps his first after defeating dominic *thiem* to reach the miami open semi finals . *murray* throws his *sweatband* into the crowd after completing a 3-6 , 6-4 , 6-1 victory in florida . murray shakes hands with *thiem* who he described as a ' strong guy ' after the game . and murray has a fairly simple message for any of his fellow british tennis players who might be agitated about his imminent arrival into the home ranks : do n't complain . instead the british no 1 believes his colleagues should use the assimilation of the world number 83 , originally from slovenia , as motivation to better themselves .

andy murray defeated dominic *thiem* 3-6 6-4 , 6-1 in an hour and three quarters . murray was awaiting the winner from the last eight match between tomas berdych and argentina 's juan monaco . prior to this tournament *thiem* lost in the second round of a challenger event to soon-to-be new brit *aljaz* bedene .


Veamos más ejemplos: *image captioning* revisitado (Xu et al., 2015)

- En el esquema seq2seq, este problema es considerado como una **traducción** desde una **imagen** a **texto** (imágenes consideradas como un lenguaje).
- Si bien puede sonar intuitivo, este esquema tiene **dos problemas fundamentales**:
 1. La ubicación de las palabras (estructuras visuales relevantes) en las imágenes no está predefinida.
 2. La lista de palabras posibles (vocabulario visual) es desconocida.




A woman with a little girl in a park, the woman is throwing a fresbee.

Veamos más ejemplos: *image captioning* revisitado (Xu et al., 2015)



Si bien hay muchas maneras de enfrentar esto, la más directa es asumir como **orden** una **grilla regular** y como **vocabulario visual** las **features** de la **última capa convolucional** de una CNN

Veamos más ejemplos: *image captioning* revisitado (Xu et al., 2015)



Veamos más ejemplos: *image captioning* revisitado (Xu et al., 2015)



A woman is throwing a frisbee in a park.



A dog is standing on a hardwood floor.



A stop sign is on a road with a mountain in the background.



A little girl sitting on a bed with a teddy bear.





A group of people sitting on a boat in the water.



A giraffe standing in a forest with trees in the background.

Veamos más ejemplos: *image captioning* mejorado con atención sobre objetos (Anderson et al., 2018)



Lecturas recomendadas

- “Visualizing A Neural Machine Translation Model”: <https://jalammar.github.io/visualizing-neural-machine-translation-mechanics-of-seq2seq-models-with-attention/>
- “Show, Attend and Tell: Neural Image Caption Generation with Visual Attention”: <https://arxiv.org/pdf/1502.03044.pdf/>

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



Deep Learning

Modelos de lenguaje

Ariel Reyes
Dpto. Ciencia de la Computación