

Pontificia Universidad Católica de Chile  
Escuela de Ingeniería  
Departamento de Ciencia de la Computación



# Deep Learning

Foundation Models

Ariel Reyes  
Dpto. Ciencia de la Computación



<https://youtu.be/-lt2j1liElg>

# AI pioneer says its threat to world may be 'more urgent' than climate change

By Martin Coulter ▾

---



¿Cómo llegamos a esta situación?

## On the Opportunities and Risks of Foundation Models


Rishi Bommasani\* Drew A. Hudson Ehsan Adeli Russ Altman Simran Arora  
Sydney von Arx Michael S. Bernstein Jeannette Bohg Antoine Bosselut Emma Brunskill  
Erik Brynjolfsson Shyamal Buch Dallas Card Rodrigo Castellon Niladri Chatterji  
Annie Chen Kathleen Creel Jared Quincy Davis Dorottya Demsky Chris Donahue  
Moussa Doumbouya Esin Durmus Stefano Ermon John Etchemendy Kavin Ethayarajh  
Li Fei-Fei Chelsea Finn Trevor Gale Lauren Gillespie Karan Goel Noah Goodman  
Shelby Grossman Neel Guha Tatsunori Hashimoto Peter Henderson John Hewitt  
Daniel E. Ho Jenny Hong Kyle Hsu Jing Huang Thomas Icard Saahil Jain  
Dan Jurafsky Pratyusha Kalluri Siddharth Karamcheti Geoff Keeling Fereshte Khani  
Omar Khattab Pang Wei Koh Mark Krass Ranjay Krishna Rohith Kudithipudi  
Ananya Kumar Faisal Ladhak Mina Lee Tony Lee Jure Leskovec Isabelle Levent  
Xiang Lisa Li Xuechen Li Tengyu Ma Ali Malik Christopher D. Manning  
Suvir Mirchandani Eric Mitchell Zanele Munyikwa Suraj Nair Avanika Narayan  
Deepak Narayanan Ben Newman Allen Nie Juan Carlos Niebles Hamed Nilforoshan  
Julian Nyarko Giray Ogun Laurel Orr Isabel Papadimitriou Joon Sung Park Chris Piech  
Eva Portelance Christopher Potts Aditi Raghunathan Rob Reich Hongyu Ren  
Frieda Rong Yusuf Roohani Camilo Ruiz Jack Ryan Christopher Ré Dorsa Sadigh  
Shiori Sagawa Keshav Santhanam Andy Shih Krishnan Srinivasan Alex Tamkin  
Rohan Taori Armin W. Thomas Florian Tramèr Rose E. Wang William Wang Bohan Wu  
Jiajun Wu Yuhuai Wu Sang Michael Xie Michihiro Yasunaga Jiaxuan You Matei Zaharia  
Michael Zhang Tianyi Zhang Xikun Zhang Yuhui Zhang Lucia Zheng Kaitlyn Zhou  
Percy Liang\*<sup>1</sup>

Center for Research on Foundation Models (CRFM)  
Stanford Institute for Human-Centered Artificial Intelligence (HAI)  
Stanford University

*AI is undergoing a paradigm shift with the rise of models (e.g., BERT, DALL-E, GPT-3) that are trained on broad data at scale and are adaptable to a wide range of downstream tasks. We call these models foundation models to underscore their critically central yet incomplete character. This report provides a thorough account of the opportunities and risks of foundation models, ranging from their capabilities (e.g., language, vision, robotics, reasoning, human interaction) and technical principles (e.g., model architectures, training procedures, data, systems, security, evaluation, theory) to their applications (e.g., law, healthcare, education) and societal impact (e.g., inequity, misuse, economic and environmental impact, legal and ethical considerations). Though foundation models are based on standard deep learning and transfer learning, their scale results in new emergent capabilities, and their effectiveness across so many tasks incentivizes homogenization. Homogenization provides powerful leverage but demands caution, as the defects of the foundation model are inherited by all the adapted models downstream. Despite the impending widespread deployment of foundation models, we currently lack a clear understanding of how they work, when they fail, and what they are even capable of due to their emergent properties. To tackle these questions, we believe much of the critical research on foundation models will require deep interdisciplinary collaboration commensurate with their fundamentally sociotechnical nature.*


<sup>1</sup>Corresponding author: pliang@cs.stanford.edu

\*Equal contribution.



# ARTIFICIAL INTELLIGENCE

Artificial Intelligence captures the imagination of the world.



# MACHINE LEARNING

Machine learning starts to gain traction.



# DEEP LEARNING

Deep learning catapults the industry.



1950s

1960s

1970s

1980s

1990s

2000s

2010s



Emergence of...

Homogenization of...


Machine Learning



"how"

learning algorithms

Deep Learning




features

architectures

Foundation Models

functionalities

models





```
> npx tsx src/demo.ts
```

```
✓ Write a python version of bubble sort.
```

Here is an implementation of bubble sort in Python:

```
...
```

```
def bubble_sort(arr):
```

```
    n = len(arr)
```

```
    for i in range(n):
```

```
        for j in range(0, n - i - 1):
```

```
            if arr[j] > arr[j + 1]:
```

```
                arr[j], arr[j + 1] = arr[j + 1], arr[j]
```

```
...
```

```
> █
```


“ Can you create an Adobe After Effects expression that blurs a shape layer when it's position is in the right half of the composition, using the Gaussian Blur effect




“ Can you create an Adobe After Effects expression that places a blinking cursor at the end of a text field




“ Can you write out an Adobe After Effects expression to make a shape layer wiggle when a null object is within 50 pixels of the shape's anchor point



“ Can you create an Adobe After Effects expression that rotates a shape layer around it's anchor point, with a radius of 100 pixels



## Model & Hardware Growth




¿Qué avance técnico permitió esto?

Modelos Seq2Seq con atención  
conceptualmente funcionan muy bien

## Neural Machine Translation

SEQUENCE TO SEQUENCE MODEL WITH ATTENTION



Je


suis

étudiant


Lamentablemente, acarrear muchos de los problemas de las RNN

Aplicación a conjuntos de datos masivos, que potencialmente entregan mayor conocimiento, es complejo debido a:

- Baja eficiencia computacional
- Problemas de predicción con secuencias muy largas




Una posible solución a estos problemas la entrega la arquitectura **Transformer**



- Esta arquitectura profunda está completamente basada en mecanismos de atención.
- Su gran aporte es ser más eficiente y permitir dependencias de mayor largo que los modelos seq2seq.




Si bien también están formados por *encoder* y *decoders*, estos **no son recurrentes**, sino combinaciones de **atención** y **capas densas**




- Atención en Transformers no es igual a la de un modelo seq2seq.
- En este caso se utiliza la **auto-atención**, que indica para cada elemento de una secuencia, su dependencia con otros elementos de la misma.


Si bien también están formados por *encoder* y *decoders*, estos **no son recurrentes**, sino combinaciones de **atención** y **capas densas**




Auto-atención resulta ser el elemento **clave**  
(más tarde pondremos un leve manto de dudas sobre esto)











Auto-atención resulta ser el elemento **clave**  
(más tarde pondremos un leve manto de dudas sobre esto)




Auto-atención resulta ser el elemento **clave**  
(más tarde pondremos un leve manto de dudas sobre esto)




Auto-atención resulta ser el elemento **clave**  
(más tarde pondremos un leve manto de dudas sobre esto)

| Input                        | Thinking                                                                                  | Machines                                                                                  |
|------------------------------|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Embedding                    | $x_1$  | $x_2$  |
| Queries                      | $q_1$  | $q_2$  |
| Keys                         | $k_1$  | $k_2$  |
| Values                       | $v_1$  | $v_2$  |
| Score                        | $q_1 \cdot k_1 = 112$                                                                     | $q_1 \cdot k_2 = 96$                                                                      |
| Divide by 8 ( $\sqrt{d_k}$ ) | 14                                                                                        | 12                                                                                        |
| Softmax                      | 0.88                                                                                      | 0.12                                                                                      |

Auto-atención resulta ser el elemento **clave**  
(más tarde pondremos un leve manto de dudas sobre esto)




Auto-atención puede ser multimodal (muchas atenciones distintas)






¿Qué pasa con el orden de las secuencias?


Orden de las secuencias se incluye a través de un *embedding* temporal




Orden de las secuencias se incluye a través de un *embedding* temporal



Finalmente, el *decoder* genera las predicciones



Finalmente, el *decoder* genera las predicciones



Transformer fue, **indirectamente**, el primer paso para la revolución

- Si bien la arquitectura fue muy novedosa, su proceso de entrenamiento es tradicional.
- Dicho de otra forma, se entrena con una tarea supervisada (*translation*), y luego se hace fine-tuning para llevar el conocimiento a otras tareas.
- Esto es problemático, ya que los datos rotulados no son suficientes para sacar todo el provecho necesario de este modelo.
- El gran gran paso fue cómo aprovechar esta poderosa arquitectura con un esquema de entrenamiento *adhoc*.

# Bert fue uno de los primeros que capitalizó sobre esta idea

## 1 - Semi-supervised training on large amounts of text (books, wikipedia..etc).

The model is trained on a certain task that enables it to grasp patterns in language. By the end of the training process, BERT has language-processing abilities capable of empowering many models we later need to build and train in a supervised way.

### Semi-supervised Learning Step

**Model:**



**Dataset:**




**Objective:**

Predict the masked word  
(language modeling)

## 2 - Supervised training on a specific task with a labeled dataset.

### Supervised Learning Step

**Model:**  
(pre-trained  
in step #1)



**Dataset:**

| Email message                              | Class    |
|--------------------------------------------|----------|
| Buy these pills                            | Spam     |
| Win cash prizes                            | Spam     |
| Dear Mr. Atreides, please find attached... | Not Spam |

El inglés no es el único lenguaje donde se ha entrenado Bert


| Task   | BETO-cased   | BETO-uncased | Best Multilingual BERT |
|--------|--------------|--------------|------------------------|
| POS    | <b>98.97</b> | 98.44        | 97.10 [2]              |
| NER-C  | <b>88.43</b> | 82.67        | 87.38 [2]              |
| MLDoc  | 95.60        | <b>96.12</b> | 95.70 [2]              |
| PAWS-X | 89.05        | 89.55        | 90.70 [8]              |
| XNLI   | <b>82.01</b> | 80.15        | 78.50 [2]              |

<https://github.com/dccuchile/beto>




El último ingrediente para el éxito es el alineamiento

## Alignment



El último ingrediente para el éxito es el alineamiento



## Tres conceptos clave sobre los Transformers

- Arquitectura para aprendizaje general (no especializada en un tipo de dato), dada (al parecer) por el sesgo inductivo del mecanismo de atención.
- Esquema de entrenamiento autosupervisado, que permite escalar sin necesidad de rotular los datos.
- Alineamiento es fundamental para obtener resultados adecuados, tanto para los humanos como para la aplicación.



Comencemos con algunos casos de uso no triviales para los modelos de lenguaje (Large Language Models o LLM): **asistentes de programación**


The image shows a web application interface with a dark theme. On the left is a sidebar with four navigation items: 'Fetch tweets' (with a Twitter icon), 'Draw a scatterplot' (with a line graph icon), 'Memoization' (with a database icon), and 'Goodreads rating' (with a book icon). The 'Goodreads rating' item is highlighted with a dark background. The main area is a code editor with tabs for 'rating.js', 'rating.py' (selected), 'rating.rb', 'rating.ts', and 'rating.go'. The Python code in the editor is as follows:

```
1 import os, requests, json, bs4
2 key = os.environ['GOODREADS_API_KEY']
3
4 def get_rating(title) :
5     """Get the average rating of the book from GoodReads, and return a float."""
6     url = 'https://www.goodreads.com/book/title.xml?key=' + key + '&title=' + title
7     response = requests.get(url)
8     soup = bs4.BeautifulSoup(response.text, 'xml')
9     rating = soup.find('average_rating').text
10    return float(rating)
```

Below the code editor is a blue button with the Copilot logo and the text 'Copilot'. At the bottom right of the interface is a 'Replay' button with a circular arrow icon.

<https://github.com/features/copilot>

Comencemos con algunos casos de uso no triviales para los modelos de lenguaje (Large Language Models o LLM): **tutores virtuales**



<https://youtu.be/4FGtvE-jJol>


Comencemos con algunos casos de uso no triviales para los modelos de lenguaje (Large Language Models o LLM): **automatización de tareas**



<https://youtu.be/4mU2yq4hU0M>

Continuemos con el uso de Transformers en imágenes, una de las modalidades de datos más abundantes y comunes

- CNNs y sus extensiones han sido la arquitectura por defecto en CV por bastantes años.
- Rendimiento y eficiencia excelentes, tanto en tareas directas o como extractor de características.
- Pero como siempre en DL, cada cierto tiempo aparece una nueva arquitectura “hot” que debe ser adaptada a este dominio.






# Enter Vision Transformer (Vit)






# Enter Vision Transformer (ViT)

Alexnet 1st conv filters




ViT 1st linear embedding filters


RGB embedding filters  
(first 28 principal components)



## Enter Vision Transformer (Vit)



ViT se ha entrenado incluso de forma auto-supervisada



## Movámonos rápidamente a la multimodalidad

- Aprendizaje de representaciones con CNNs o ViT para transferencia de conocimiento es quizá el caso de uso principal en CV.
- Si bien los resultados son tremendamente exitosos, existe mucho que estos métodos no están capturando.
- En particular, el *grounding* entre texto y visión es algo que resulta muy natural para los humanos, pero que no ha sido típicamente considerado en los modelos.



girl  
**eats**  
ice cream

girl  
**stares at**  
ice cream

CLIP enfrenta esto usando Transformers y **aprendizaje contrastivo** sobre 400 millones de pares imagen-texto

Encode the images  
and text snippets




Image Encoder

a red delicious apple


a black office chair

a corgi dog


Text Encoder

Una vez entrenado, CLIP permite hacer *zero-shot classification*

### 1. Contrastive pre-training



### 2. Create dataset classifier from label text



### 3. Use for zero-shot prediction

Una vez entrenado, CLIP permite hacer *zero-shot classification*

#### FOOD101

**guacamole** (90.1%) Ranked 1 out of 101 labels



- ✓ a photo of **guacamole**, a type of food.
- ✗ a photo of **ceviche**, a type of food.
- ✗ a photo of **edamame**, a type of food.
- ✗ a photo of **tuna tartare**, a type of food.
- ✗ a photo of **hummus**, a type of food.

#### YOUTUBE-BB


**airplane, person** (89.0%) Ranked 1 out of 23



- ✓ a photo of a **airplane**.
- ✗ a photo of a **bird**.
- ✗ a photo of a **bear**.
- ✗ a photo of a **giraffe**.
- ✗ a photo of a **car**.

#### PATCHCAMELYON (PCAM)

**healthy lymph node tissue** (22.8%) Ranked 2 out of 2



- ✗ this is a photo of lymph node tumor tissue
- ✓ this is a photo of **healthy lymph node tissue**

#### SUN397


**television studio** (90.2%) Ranked 1 out of 397



- ✓ a photo of a **television studio**.
- ✗ a photo of a **podium indoor**.
- ✗ a photo of a **conference room**.
- ✗ a photo of a **lecture room**.
- ✗ a photo of a **control room**.

#### EUROSAT

**annual crop land** (12.9%) Ranked 4 out of 10



- ✗ a centered satellite photo of **permanent crop land**.
- ✗ a centered satellite photo of **pasture land**.
- ✗ a centered satellite photo of **highway or road**.
- ✓ a centered satellite photo of **annual crop land**.
- ✗ a centered satellite photo of **brushland or shrubland**.

#### IMAGENET-A (ADVERSARIAL)


**lynx** (4.2%) Ranked 5 out of 200



- ✗ a photo of a **fox squirrel**.
- ✗ a photo of a **mongoose**.
- ✗ a photo of a **skunk**.
- ✗ a photo of a **red fox**.
- ✓ a photo of a **lynx**.




CLIP se puede usar para prácticamente cualquier tarea visual




Overlay automático de sonido en edición de video




Modelos de difusión han sido también un gran avance



Modelos de difusión han sido también un gran avance




Modelos de difusión han sido también un gran avance



Modelos de difusión han sido también un gran avance



Al combinar estos últimos dos modelos, llegamos a la arquitectura de DALL-E 2





TEXT DESCRIPTION

An astronaut    Teddy bears    A bowl of  
soup

riding a horse    lounging in a tropical resort  
in space    playing basketball with cats in  
space

in a photorealistic style    in the style of Andy  
Warhol    as a pencil drawing



DALL-E 2




<https://openai.com/dall-e-2/>

Finalmente, DALL-E 3 utiliza GPT4 para generar texto más detallado, lo que colabora con la generación de imágenes





Finalmente, DALL-E 3 utiliza GPT4 para generar texto más detallado, lo que colabora con la generación de imágenes



DALL-E 2



DALL-E 3



## Cómo conviene escalar estos modelos (en todo sentido)

- Por primera vez en historia de la IA, pareciera no haber límite en cuanto al escalamiento en tamaño de un modelo y la cantidad de datos a utilizar.
- Trabajos recientes han estudiado leyes de escala para estas variables, principalmente en modelos de lenguaje.
- Ajuste de estas leyes a resultados empíricos son altamente precisas, dando nuevos *insights* sobre hacia donde apuntar a futuro.

$$L(N, D) = \frac{A}{N^\alpha} + \frac{B}{D^\beta} + E$$


Datos son por lejos el elemento dominante

$$L(N, D) = \underbrace{\frac{406.4}{N^{0.34}}}_{\text{finite model}} + \underbrace{\frac{410.7}{D^{0.28}}}_{\text{finite data}} + \underbrace{1.69}_{\text{irreducible}}$$


Gopher (280 mil millones de parámetros):  $L(280 \cdot 10^9, 300 \cdot 10^9) = \underbrace{0.052}_{\text{finite model}} + \underbrace{0.251}_{\text{finite data}} + \underbrace{1.69}_{\text{irreducible}} = 1.993$

Chinchilla (70 mil millones de parámetros):  $L(70 \cdot 10^9, 1400 \cdot 10^9) = \underbrace{0.083}_{\text{finite model}} + \underbrace{0.163}_{\text{finite data}} + \underbrace{1.69}_{\text{irreducible}} = 1.936$


Datos son por lejos el elemento dominante



Datos son por lejos el elemento dominante




Datos son por lejos el elemento dominante, pero no tenemos suficientes



# Sobre el leve manto de dudas con respecto a la autoatención

- Un reciente trabajo\* (13/09/23) cuestiona la importancia de la autoatención, mostrando que lo más importante es la predicción autoregresiva del siguiente elemento de la secuencia.
- La idea central es que los elementos autoregresivos funcionen como buenas features de entrada para la siguiente predicción. En caso de no serlo, la arquitectura de la red debe ser capaz de generar estas features.
- Esto presenta un trade-off entre rotulado de datos vs tamaño de la arquitectura.

## Shallow MLP



\* <https://arxiv.org/pdf/2309.06979.pdf>

# Sobre el leve manto de dudas con respecto a la autoatención

|                         |                                                                                                                                                                                                   |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Prompt #1:</b>       | Once upon a                                                                                                                                                                                       |
| <b>Output (Linear):</b> | <i>Once upon a time, there was a little boy named Tim. Tim was very hungry. He wanted to eat some food. He asked his mom, "Can I eat some soup, please?" His mom said, "Yes, but be careful."</i> |

|                         |                                                                                                                                                                                                                                                                        |
|-------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Prompt #2:</b>       | He was very scared                                                                                                                                                                                                                                                     |
| <b>Output (Linear):</b> | <i>He was very scared. He cried out loud, but then he heard a voice. He was afraid of the dark monster. He ran to the bear. He had a pain in his hand. He screamed and ran away. He was never seen again. He was scared of the monster and he went on. He never...</i> |

|                          |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Prompt:</b>           | 1394×8618=                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <b>Output (MLP):</b>     | $\begin{aligned} &(4\times1+9\times10+3\times100+1\times1000)\times \\ &(8\times1+1\times10+6\times100+8\times1000)= \\ &4\times8\times1\times1+4\times1\times1\times10+4\times6\times1\times100+ \\ &4\times8\times1\times1000+9\times8\times10\times1+9\times1\times10\times10+ \\ &9\times6\times10\times100+9\times8\times10\times1000+3\times8\times100\times1+ \\ &3\times1\times100\times10+3\times6\times100\times100+ \\ &3\times8\times100\times1000+1\times8\times1000\times1+ \\ &1\times1\times1000\times10+1\times6\times1000\times100+ \\ &1\times8\times1000\times1000= \\ &32+040+2400+32000+720+0900+54000+ \\ &720000+2400+03000+180000+2400000+ \\ &08000+010000+0600000+08000000= \\ &12013492 \end{aligned}$ |
| <b>Output (GPT-3.5):</b> | The multiplication of 1394 by 8618 is equal to 12,013,692.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <b>Output (GPT-4):</b>   | The multiplication of 1394 and 8618 equals 12,014,052.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| <b>Correct Answer:</b>   | 12013492                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |

## Algunas ideas para terminar (la clase y el curso)

- Grandes compañías *Tech* ya ofrecen “**AI as a service**” en plataformas cloud, incluyendo casi todos los modelos y técnicas que hemos visto.
- Sin embargo, usos más específicos siempre requerirán entender los **fundamentos** y **detalles**.
- ***Foundation models*** serán el paradigma dominante por los siguientes años, primero con usos más “flashy” y luego más prácticos.
- **No se les olvide nunca seguir estudiando sobre esto, ya que el paisaje cambia año a año.**



Pontificia Universidad Católica de Chile  
Escuela de Ingeniería  
Departamento de Ciencia de la Computación



# Deep Learning

Foundation Models

Ariel Reyes  
Dpto. Ciencia de la Computación