



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DIPLOMADO EN MACHINE LEARNING APLICADO

Fundamentos de Machine Learning

Control 1

29 de Mayo de 2024

Aspectos preliminares

El objetivo de esta evaluación aplicar los contenidos de las dos primeras clases.

El control consta de tres preguntas de las cuales ustedes deben escoger solo 2 para contestar (la elección de estas dos preguntas incluye todos sus incisos, no deben mezclar incisos).

Pregunta 1

Un fabricante de hardware se encuentra en el proceso de diseño de una nueva generación de CPUs para dispositivos móviles, cuya principal característica es un mecanismo adaptativo de activación/desactivación de los núcleos (cores), en base a al comportamiento de los usuarios. Con el fin de ponerse a tono con el mercado mundial, el equipo de desarrollo planea utilizar técnicas de Machine Learning para construir el sistema de activación de núcleos.

1. Indique como podría enfrentar el equipo desarrollador este problema. Especifique claramente que tipo de aprendizaje utilizaría, y qué ventaja tendría esto por sobre un sistema basado en reglas. **(2 ptos.)**
2. Con el fin de entrenar los modelos, el equipo de desarrollo recolectó un gran volumen de datos de uso de las nuevas CPUs, desde los computadores de sus propios integrantes. Comente sobre las ventajas y desventajas de esta decisión. **(2 ptos.)**
3. ¿Cómo podría utilizarse un esquema de vecinos más cercanos en este contexto? ¿Cómo se compararía esto con la creación de perfiles de uso? **(2 ptos.)**

Solución: 1. Podría ser tanto aprendizaje supervisado como no supervisado. Las principales ventajas podrían ser: adaptabilidad, precisión, escalabilidad y reducción de errores humanos.

2. Ventajas: disponibilidad inmediata de datos, control de la calidad de los datos y rapidez en la iteración

Desventajas: sesgo de muestra, diversidad limitada tamaño de muestra reducido.

3. Un esquema de vecinos más cercanos podría ser utilizado para determinar la activación o desactivación de núcleos basándose en la similitud de patrones de uso actuales con patrones observados previamente. El algoritmo k-NN evaluaría el comportamiento actual del dispositivo y encontraría los casos más similares en el conjunto de datos históricos para predecir la configuración óptima de los núcleos.

Ventajas de perfiles de uso: Permiten una personalización más dirigida y pueden ser más eficientes en términos de computación si los perfiles son bien definidos y el número de perfiles es limitado.

Desventajas de perfiles de uso: Requieren una fase inicial de identificación y clasificación de perfiles, lo que puede ser complejo y demandar tiempo. Además, los usuarios pueden cambiar de perfil con el tiempo, lo que requeriría ajustes continuos.

□

Pregunta 2

1. ¿Como se podría realizar clasificación con un árbol de decisión, si falta el valor de alguna de las dimensiones del vector de entrada? **(1 pto.)**
2. Indique como utilizaría validación cruzada para estimar la mejor profundidad de un árbol de decisión. **(1 pto.)**
3. Considere un problema de clasificación sobre variables categóricas. Extienda el algoritmo de construcción de los árboles de decisión basado en la ganancia de información, para que se puedan realizar tests sobre dos variables de manera simultánea. **(2 ptos.)**
4. En general, al momento de decidir el valor a testear en un nodo de un árbol de decisión, se toma la ganancia de información como métrica. Una de las desventajas de esta, es que no considera la nueva estructura del árbol en el cálculo (la resultante de seleccionar ese test, con distinta profundidad y número de nodos), lo que puede derivar en problemas de sobreentrenamiento. Extienda la métrica de la ganancia de información, sumando un nuevo término, de manera que ahora, para tomar la decisión, se considere información sobre la posible nueva estructura del árbol. **(2 ptos.)**

Solución: 1. Asignación del valor más común, asignación media, asignación basada en distribución o crear una rama adicional en el árbol que maneje específicamente los casos donde falta el valor.

2. Dividir el conjunto de datos k partes. Entrenar el árbol de decisión en $k - 1$ partes y validar en la parte restante. Repetir este proceso k veces, cambiando la parte de validación en cada iteración.

Repetir el proceso de validación cruzada para diferentes profundidades del árbol y seleccionar la mejor profundidad.

3. Para cada nodo del árbol, en lugar de evaluar la ganancia de información de una sola variable, considerar todas las posibles combinaciones de pares de variables. Luego calcular la ganancia de información conjunta para cada par de variables. Esto implica evaluar cómo la partición basada en las combinaciones de valores de las dos variables afecta la entropía del conjunto de datos. Finalmente seleccionar el par de variables que maximice la ganancia de información conjunta y utilizar este par para realizar la partición en el nodo.
4. Para extender la métrica de la ganancia de información y considerar la nueva estructura del árbol, podemos agregar un término que penalice la complejidad del árbol. Esto se puede hacer de la siguiente manera:

Definición del término de penalización: Introducir un término de penalización $\alpha \times$ complejidad del árbol, donde α es un parámetro que controla el nivel de penalización por complejidad. La complejidad del árbol puede ser medida en términos de la profundidad del árbol y el número de nodos.

Métrica ajustada: La métrica ajustada para seleccionar el mejor test en un nodo sería:

$$\text{Ganancia de Información Ajustada} = IG - \alpha \times (n + h),$$

donde IG es la ganancia de información, n la cantidad de nodos y h la profundidad del árbol.

Selección basada en la métrica ajustada: Utilizar esta métrica ajustada para decidir el mejor test en cada nodo del árbol, lo que ayudará a reducir el sobreentrenamiento al penalizar estructuras de árbol demasiado complejas.

□

Pregunta 3

1. ¿Cómo obtendría los mejores hiperparámetros para un árbol de regresión (profundidad máxima, por ejemplo), si posee un conjunto de datos pequeño? **(2 ptos.)**
2. Considere un espacio de características igual a $\mathbb{R}^{20}$. ¿Por qué motivo los árboles de decisión particionan este espacio de características mediante líneas rectas paralelas a los ejes? **(2 ptos.)**
3. Con respecto a la pregunta anterior, ¿cómo se debería modificar un árbol de decisión para que genera particiones basadas en rectas con pendiente arbitraria (no necesariamente ortogonales a los ejes)? **(2 ptos.)**

- Solución:*
1. Posibles pasos: validación cruzada, búsqueda por rejillas y evaluación del modelo.
 2. Los árboles de decisión particionan el espacio de características mediante líneas rectas paralelas a los ejes debido a su naturaleza jerárquica y de toma de decisiones univariadas. En cada nodo del árbol, se selecciona una única característica para realizar una partición basada en un umbral específico. Esto significa que cada división es una decisión basada en una sola característica, lo que resulta en una partición que es paralela al eje de la característica seleccionada. Matemáticamente, esto se puede representar como:

$$x_i \leq \text{umbral} \quad \text{o} \quad x_i > \text{umbral}$$

donde x_i es la i -ésima característica.

3. Para modificar un árbol de decisión de manera que pueda generar particiones basadas en rectas con pendiente arbitraria, se pueden seguir los siguientes enfoques:
 - **Árboles oblicuos (Oblique Decision Trees):** Implementar árboles de decisión oblicuos, donde en cada nodo se utiliza una combinación lineal de múltiples características para la partición. Esto se puede representar como:

$$\mathbf{w} \cdot \mathbf{x} \leq \text{umbral} \quad \text{o} \quad \mathbf{w} \cdot \mathbf{x} > \text{umbral}$$

donde $\mathbf{w}$ es un vector de pesos y $\mathbf{x}$ es el vector de características. El entrenamiento de estos árboles implica encontrar los pesos $\mathbf{w}$ que mejor separen los datos en cada nodo.

- **Árboles de Decisión Basados en Separación de Hiperplanos:** Permitir que las particiones en los nodos sean determinadas por hiperplanos arbitrarios en lugar de líneas paralelas a los ejes. Esto requiere resolver un problema de optimización en cada nodo para determinar la mejor orientación del hiperplano.

□