

Pregunta 1

- a) Considere un problema de clasificación con 11 categorías, donde el espacio de características es $\mathbb{R}^n$. Explique en detalle como construiría un gráfico de rendimiento vs complejidad para un clasificador de k -vecinos cercanos, donde ambos ejes presentan cantidades crecientes. ¿Cómo seleccionaría el modelo de complejidad óptima para este problema? **(2 ptos.)**
- b) Considere el mismo conjunto de datos del ítem anterior, pero ahora con valores faltantes (registros con uno o más características sin valor). ¿Cómo podríamos utilizar el algoritmo de k -vecinos cercanos para completar estos valores? ¿qué pasa si los valores a completar son categóricos no ordenables (por ejemplo, colores)? **(2 ptos.)**
- c) Considere ahora un conjunto de datos para una tarea de clasificación, donde el espacio de características solo corresponde a variables categóricas no ordenables. Indique como modificaría el algoritmo de k -vecinos cercanos para trabajar con un conjunto de datos de estas de este tipo. **Hint:** piense en en la métrica de distancia y/o los datos. **(2 ptos.)**

Pregunta 2

- a) Considere un problema de clasificación sobre variables categóricas. Extienda el algoritmo de construcción de los árboles de decisión basado en la ganancia de información, para que se puedan realizar tests sobre dos variables de manera simultánea **(2 ptos.)**.
- b) En general, al momento de decidir la característica a utilizar en un nodo de un árbol de decisión, se toma la ganancia de información como métrica. Una de las desventajas de esta, es que no considera la nueva estructura del árbol en el cálculo (la resultante de seleccionar esa característica), lo que puede derivar en problemas de sobreajuste. Extienda la métrica de la ganancia de información, sumando un nuevo término a esta, de manera que ahora, para tomar la decisión, se considere información sobre la posible nueva estructura del árbol. **(2 ptos.)**
- c) Considere una competencia donde se debe resolver un problema de regresión en base a variables categóricas. Dado que en este problema el riesgo de sobreajuste es alto, solo se permite utilizar árboles de regresión de profundidad 1 (usando solo una (1) de las variables disponibles). Utilizando múltiples árboles de este tipo de **manera secuencial** (cada árbol puede utilizar la variable que quiera), indique cómo construir incrementalmente un modelo de regresión para la competencia. **(2 ptos.)**

Pregunta 3

- a) ¿Cuál es el efecto que producen en los modelos de ML vistos hasta ahora, los ejemplos repetidos en un set de datos? Analice de manera independiente para cada uno de ellos. **(1 pto.)**
- b) ¿Cómo combinaría los resultados de dos modelos distintos entrenados para la misma tarea sobre los mismos datos, de modo de generar un mejor modelo? **(1 pto.)**
- c) ¿Cómo obtendría los mejores hiperparámetros para un árbol de regresión (profundidad máxima, por ejemplo), si posee un conjunto de datos pequeño? **(1 pto.)**
- d) Considere un espacio de características igual a $\mathbb{R}^{20}$. ¿Por qué motivo los árboles de decisión particionan este espacio de características mediante líneas rectas paralelas a los ejes? **(1 pto.)**
- e) Con respecto a la pregunta anterior, ¿cómo se debería modificar un árbol de decisión para que genera particiones basadas en rectas con pendiente arbitraria (no necesariamente ortogonales a los ejes)? **(1 pto.)**
- f) Considere un conjunto de puntos en $\mathbb{R}^{10}$, que se ubican únicamente sobre la superficie de una hipersfera de 9 dimensiones, y donde cada uno pertenece a una de cinco categorías. ¿Qué métrica de distancia debiese usarse si se utiliza un algoritmo de k-NN para la clasificación de estos puntos? **(1 pto.)**