

Pregunta 1

Al igual que los árboles de decisión, un *random forest* busca que los tests realizados en cada nodo separen de la mejor manera posible a las categorías a predecir. A pesar de que en general se utilizan umbrales para los tests con variables numéricas, nada impide que los tests se realicen de otra manera, en particular, utilizando un clasificador. Asumiendo que se tiene un set de datos de clasificación multiclase, donde todos los atributos son numéricos, conteste las siguientes preguntas:

- a) ¿Qué tipo de clasificador utilizaría para los nodos? Considere que el clasificador debe permitir variar su complejidad, de modo que permita disminuir la correlación de los distintos árboles del *random forest*. **(2.0 pts.)**
- b) Describa detalladamente como construir este nuevo tipo de *random forest*, ya sea indicando el proceso o el problema de optimización asociado. **(2.0 pts.)**
- c) ¿Como controlaría el *overfitting* de cada uno de los árboles? **(2.0 pts.)**

Pregunta 2

- a) En base a la solución al problema de optimización dual de los SVM, indique cómo se identifican los vectores de soporte, y qué condiciones cumplen. **(2.0 pts.)**
- b) Considere dos conjuntos de puntos en $\mathbb{R}^n$, A y B , donde cada punto en ellos tiene asociada una etiqueta binaria que puede ser -1 o 1. ¿Es necesario que A y B sean iguales para que los SVM entrenados sobre ellos (uno para A y otro para B) sean iguales? ¿Si no, qué se debe cumplir para que esto ocurra? Justifique su respuesta. **(2.0 pts.)**
- c) Un *Double Soft-margin SVM* es un algoritmo de clasificación similar a un *Soft-margin SVM*, pero que impone dos restricciones sobre el margen: una sobre su valor mínimo (*Soft-margin SVM*) y una sobre el máximo. A partir de esto, defina el problema de aprendizaje para un *Double Soft-margin SVM*, como un problema de minimización cuadrático con restricciones lineales. **(2.0 pts.)**