

Clase 4:

Sistemas Recomendadores

Vicente Domínguez

Diplomado en Machine Learning Aplicado UC




Programa del Curso

1. Introducción , Recomendación No personalizada , Filtrado Colaborativo (User y Item), Evaluación basada en métricas de error (RMSE, MAE) + **Práctico**.
2. Slope One , Recomendación basada en métodos latentes (Factorización Matricial) + Práctico.
3. Recomendación basada en feedback implícito , Optimización basada en ALS y BPR, Evaluación basada en métricas de ranking, novedad, serendipia + Práctico.
4. Recomendación basada en contenido (text mining , nlp , aplicación) + **Práctico**.
5. Recomendación basada en contexto, ensembles y recomendación híbrida. + **Práctico**.
6. Deep Learning para recomendación (texto , imágenes, multimodal, secuencial) + **Práctico**.
7. Reinforcement Learning (Bandits) + Conversational Recsys + **Práctico**
8. Repaso general , dominios de aplicación e investigación reciente , recomendación basada en grafos.

Evaluación


Promedio ejercicios prácticos.

Tiempo para realizarlos. Al final de la clase y luego 1 semana (se entrega en la siguiente clase)



En esta clase


1. Repaso de implicit feedback , ALS , BPR y métricas de ranking
2. Concepto de Recomendación basada en contenido
3. Text Mining y NLP
4. Aplicación de Recomendación basada en contenido.



Repaso



Esquema de recomendación



Retroalimentación Implícita o Implicit Feedback

- Hu, Y., Koren, Y., & Volinsky, C. (2008) modificaron el modelo de SVD para incluir *feedback* implícito

Binarización de los datos

$$p_{ui} = \begin{cases} 1 & \text{si } r_{ui} > 0 \\ 0 & \text{si } r_{ui} = 0 \end{cases}$$

Ej. lo compra o no lo compra?
interacción?

Función de confianza

$$c_{ui} = 1 + \alpha r_{ui}$$

Ej. - dwell time (más tiempo , mayor score)
- monto \$

Función de pérdida (Implicit Funk SVD)

$$\min_{x^*, y^*} \sum_{u, i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda (||x_u||^2 + ||y_i||^2)$$

Alternate Least Squares

Con el enfoque de ALS usamos la misma idea pero alternamos iterativamente entre optimizar U y fijar V y viceversa. Hacemos esto para que cada iteración se acerque más a $R = U \times V$.

$$\min_{x^*, y^*} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda (||x_u||^2 + ||y_i||^2)$$

	item 1	item 2	item 3	...	item n
user 1					
user 2					
user 3					
user 4					
user 5					
user 6					
user 7					
user 8					
...					
user n					

R

$\approx$

	feature 1	feature 2
user 1		
user 2		
user 3		
user 4		
user 5		
user 6		
user 7		
user 8		
...		
user n		

U

	item 1	item 2	item 3	...	item n
feature 1					
feature 2					

V

Bayesian Personalized Ranking (BPR)

BPR aprende un vector latente de usuario y de ítem minimizando una función de pérdida basada en comparación de pares de ítems consumidos por cada usuario.




Figure 1: On the left side, the observed data S is shown. Learning directly from S is not feasible as only positive feedback is observed. Usually negative data is generated by filling the matrix with 0 values.




Figure 2: On the left side, the observed data S is shown. Our approach creates user specific pairwise preferences $i >_u j$ between a pair of items. On the right side, plus (+) indicates that a user prefers item i over item j ; minus (-) indicates that he prefers j over i .

Métricas de ranking [1/2]

$$\text{Precisión} = \frac{|\text{Recomendados} \cap \text{Relevante}|}{|\text{Recomendados}|}$$

$$\text{Recall} = \frac{|\text{Recomendados} \cap \text{Relevantes}|}{|\text{Relevantes}|}$$

$$MRR = \frac{1}{r}$$

r : posición del 1er elemento relevante

$$\text{Precision@}n = \frac{1}{n} \sum_{i=1}^n \text{Rel}(i)$$

$\text{Rel}(i) = 1$ si el ítem i es relevante

Métricas de ranking [2/2]

$$AP = \frac{\sum_{i=1}^n \text{Precision@5} \times \text{Rel}(i)}{|\text{Relevantes}|}$$

$$\text{DCG}_p = \sum_{i=1}^p \frac{2^{\text{rel}_i} - 1}{\log_2(1 + i)}$$

$$MAP = \frac{1}{N} \sum_{u=1}^N AP(u)$$

N : número de usuarios o listas recomendadas

$$n\text{DCG}_p = \frac{\text{DCG}_p}{i\text{DCG}_p}$$

Reflexión

Hasta ahora hemos generado recomendación basada en interacciones en común con otros usuarios.

¿Cómo podemos hacer uso del contenido de características propias de los ítems y/o de los usuarios?

En esta clase

1. Recomendación basada en contenido
2. Conceptos de Text Mining y NLP



1. Recomendación basada en contenido





Recomendación basada en contenido

- El filtrado colaborativo funciona bien pero tiene el problema de *cold-start* y *new item*.
- Tenemos **el filtrado basado en contenido** como alternativa.

Recommended Artwork	
 Successfully rated! ★★★★★	it's 81.96% similar to this artwork that you like 

Recomendación basada en contenido



Doc_1 = {w_1, w_2, ..., w_3}



Doc_2 = {w_1, w_2, ..., w_3}



Doc_3 = {w_1, w_2, ..., w_3}



Doc_n = {w_1, w_2, ..., w_3}

user_profile = {w_1, w_2, ..., w_3} usando
TF-IDF




Fig. 3.1: High level architecture of a Content-based Recommender




Fig. 3.1: High level architecture of a Content-based Recommender




Fig. 3.1: High level architecture of a Content-based Recommender

2. Conceptos de Text Mining y NLP



Los conjuntos de datos que estamos acostumbrados (estructurados) se ven así:

	Atrib. 1	Atrib.2	Atrib. 3	Atrib. 4	Atrib. 5	Atrib. 6	Atrib. 7	Atrib. 8
Obj. 1	0	0	1	2	7	0	1	0
Obj. 2	1	1	5	8	0	0	1	0
Obj. 3	1	1	0	0	5	9	3	1
Obj. 4	3	7	3	6	3	8	2	2

Persona: edad, ciudad , estado civil ,

Los conjuntos de datos que hemos estudiado se ven así:

	Atrib. 1	Atrib.2	Atrib. 3	Atrib. 4	Atrib. 5	Atrib. 6	Atrib. 7	Atrib. 8
Obj. 1	0	0	1	2	7	0	1	0
Obj. 2	1	1	5	8	0	0	1	0
Obj. 3	1	1	0	0	5	9	3	1
Obj. 4	3	7	3	6	3	8	2	2

Pero los documentos se ven así:


A pesar del fallido intento de la candidata presidencial de la DC, Carolina Goic, por cerrar la disputa con gesto al oficialismo por su respaldo unitario a favor del proyecto de elección de gobernadores regionales, esta tarde su coordinador político de campaña, Jorge Burgos, salió a defenderse tras los dichos sobre la izquierdización de la campaña de Alejandro Guillier, al nombrar como vocera a la comunista Karol Cariola. "No ocupé términos peyorativos o deshonorosos; solo establecí una posición sobre decisión de la candidatura de Guillier de otorgarle una vocería principal a la diputada, del significado que puede tener", explicó Burgos.

En condiciones de pasar a su segundo trámite legislativo al Senado quedó el proyecto que regula la elección de los nuevos gobernadores regionales, ello luego que la iniciativa fuera aprobada en general por la Cámara de Diputados. La propuesta legal, que permite viabilizar la reforma constitucional de diciembre de 2016, fue objeto de un amplio debate, tanto en la sesión del miércoles pasado, cuando se inició la discusión, como en la presente sesión. En ambas oportunidades, los discursos manifestaron la voluntad descentralizadora de los legisladores, hecho que se ratificó a la hora de aprobar la idea de legislar de gran parte de las normas.

Chile colocó el martes deuda soberana en los mercados internacionales por unos 2.300 millones de dólares, mediante la reapertura de una emisión en euros, la oferta de un nuevo bono en dólares y la recompra de bonos.

En una primera operación, el Gobierno chileno realizó la reapertura de un bono por 700 millones de euros, con un rendimiento del 1,534 por ciento y una demanda que superó en dos veces la oferta.

¿Cómo representamos los documentos
para poder procesarlos con un
computador?



Corpus

Un **corpus** es un conjunto de documentos.

Ejemplo:

- **Documento 1:** Un auto rojo
- **Documento 2:** Un tomate rojo y un globo rojo.
- **Documento 3:** Un plátano amarillo y un tomate verde.



Documento

Un documento podría ser, por ejemplo

- **Cada línea de un archivo de texto**
- **Cada archivo de texto dentro de una carpeta**
- **Un campo particular dentro de una base de datos relacional**
- **Otros...**



Vocabulario

Un **vocabulario** es una secuencia ordenada de **palabras** con un un identificador único.


Ejemplo:

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y



Otras Definiciones


- **Término (Term)** – palabra específica para el dominio en el que estamos trabajando.
- **Palabra (Word)** – palabra (string) tal como aparece en texto.
- **(Token)** – una instancia de una palabra que ocurre en un documento.



Bag of Words (*bolsa de palabras*)

Representamos un documento como una **bolsa de palabras**, sin considerar el orden de éstas.

Un tomate rojo y un
globo rojo.



Bag of Words (*bolsa de palabras*)

Podemos representar la bolsa de palabras de forma numérica, en una matriz

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc. 1									
Doc. 2									
Doc. 3									

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y

Bag of Words (*bolsa de palabras*)

Podemos representar la bolsa de palabras de forma numérica, en una matriz

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc. 1	0	1	0	0	1	0	1	0	0
Doc. 2	0	0	1	0	2	1	2	0	1
Doc. 3	0	0	0	1	0	1	2	1	1

ID	palabra
1	amarillo
2	auto
3	globo
4	plátano
5	rojo
6	tomate
7	un
8	verde
9	y


Pesos de las palabras (weighting)

La representación *Bag of Words* le asigna la misma importancia a cada palabra. ¿Está bien esto? ¿Todas las palabras nos entregan la misma cantidad de información?

- Palabras comunes:
 - Palabras como *el*, *y*, *la*, *de*, *con* que no me entregan mucha información sobre el documento.
- Palabras poco comunes:
 - Palabras como *mitocondria* me dan información acerca del contenido del texto.

Pesos de las palabras (weighting)

Dada una consulta $q = \{\text{alexis}\}$



- Otra estrategia para “pesar” las palabras: logaritmo

$$w_{t,d} = \begin{cases} 1 + \log_{10} \text{tf}_{t,d} & \text{if } \text{tf}_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$$

si la palabra “alexis” aparece muchas veces en los documentos debería tener más importancia.

- $\text{tf}_{t,d} \rightarrow w_{t,d}$: $0 \rightarrow 0, 1 \rightarrow 1, 2 \rightarrow 1.3, 10 \rightarrow 2, 1000 \rightarrow 4$, etc.

log10 se utiliza para suavizar este efecto.

Tf-idf (*term frequency - inverse document frequency*)

Podemos asignarle un peso a cada palabra de acuerdo a en cuántos documentos aparece.

$$\text{idf}(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

Donde ***N*** es la cantidad de documentos en el **corpus** y $|\{d \in D : t \in d\}|$ es la cantidad de documentos en los que aparece la palabra ***t***.

Castigar si la palabra es muy frecuente en el corpus, puede ser una stop word.

Tf-idf (*term frequency - inverse document frequency*)

$$\text{idf}(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

ID	palabra	idf
1	amarillo	
2	auto	
3	globo	
4	plátano	
5	rojo	
6	tomate	
7	un	
8	verde	
9	y	

Tf-idf (*term frequency - inverse document frequency*)

$$\text{idf}(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

ID	palabra	idf
1	amarillo	0,48
2	auto	0,48
3	globo	0,48
4	plátano	0,48
5	rojo	0.17
6	tomate	0.17
7	un	0
8	verde	0,48
9	y	0.17

Tf-idf (*term frequency - inverse document frequency*)

Para representar los documentos multiplicamos la frecuencia de cada palabra **tf** por el peso calculado **idf**

Documento 1: Un auto rojo

Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc. 1									
Doc. 2									
Doc. 3									

ID	palabra	idf
1	amarillo	0,48
2	auto	0,48
3	globo	0,48
4	plátano	0,48
5	rojo	0.17
6	tomate	0.17
7	un	0
8	verde	0,48
9	y	0.17

Tf-idf (*term frequency - inverse document frequency*)

Para representar los documentos multiplicamos la frecuencia de cada palabra **tf** por el peso calculado **idf**

Documento 1: Un auto rojo


Documento 2: Un tomate rojo y un globo rojo.

Documento 3: Un plátano amarillo y un tomate verde.

	1	2	3	4	5	6	7	8	9
Doc. 1	0	0,48	0	0	0.17	0	0	0	0
Doc. 2	0	0	0	0	0.34	0	0	0	0
Doc. 3	0,48	0	0	0,48	0	0.17	0	0,48	0.17

ID	palabra	idf
1	amarillo	0,48
2	auto	0,48
3	globo	0,48
4	plátano	0,48
5	rojo	0.17
6	tomate	0.17
7	un	0
8	verde	0,48
9	y	0.17

Procesamiento de texto



por ejemplo:

- Para modelos de lenguaje basados en contexto puede influir remover stopwords “NO”, pues cambia el sentido de la oración particular (contexto)
- A veces palabra original sin stemming puede tener sentido en otro contexto

Conceptos NLP: lematización



Lematización (reduce redundancia):

- reducir palabras a su raíz semántica.
- ejemplo: jugando, jugabais, jugamos → jugar
- ejemplo: resurrección → resucitar.

Conceptos NLP: stemming

Form	Suffix	Stem
stud ies	-es	studi
stud ying	-ing	study
niñ as	-as	niñ
niñ ez	-ez	niñ

Stemming (reduce redundancia):

- elimina el sufijo de una palabra.

Otro tipo de reducción de redundancia de palabras, pero en este caso elimina el sufijo de la palabra.

Conceptos NLP: collocations (n-gramas frecuentes)

- **Tarea:** encontrar significado conjunto de palabras:
 - Ministerio de educación
 - Policía de Investigaciones
 - Inteligencia Artificial
- Encontrar colocaciones mejora la representación del contenido.
- Cada colocación puede ser procesada como un solo token.
- Se pueden detectar analizando co-ocurrencia de n-gramas, se fija un límite de co-ocurrencia

QUERY = [0.2938, 0.46453]

DOCUMENTO1 = [.2938 , .128]

	palabra 1	palabra 2	score
documento 1	0.2938	0.128	0.1923
documento 2	0,3948	0.9087	0.9283

.....
10000

2. Modelos de lenguaje



Modelos de lenguaje

WORD2VEC

BERT




Formulación de modelo de lenguaje

- Un modelo de lenguaje permite calcular la probabilidad de una palabra (o n-grama) dada una serie de “eventos” (palabras o n-gramas) observados:

$$\begin{aligned} P(w_{1:n}) &= P(w_1)P(w_2|w_1)P(w_3|w_{1:2}) \dots P(w_n|w_{1:n-1}) \\ &= \prod_{k=1}^n P(w_k|w_{1:k-1}) \end{aligned}$$

Vectorización de texto




Idea clave: Palabras en contextos similares tendrán una representación similar.

Vectorización de texto

$x = \text{"I love to eat"} \rightarrow \text{CONTEXTO } h(w)$

$y = \text{"pizzas"} \rightarrow \text{SIGUIENTE PALABRA}$


Tarea: predecir la palabra siguiente más probable de ocurrir dado un contexto.



Vectorización de texto

$x = \text{"I love to eat"} \rightarrow \text{CONTEXTO } h(w)$

$y = ? \rightarrow \text{SIGUIENTE PALABRA}$



VOCAB X DIMENSION LATENTE (300)

PALABRA ID =1 $\Rightarrow$ [0.2038, 0.203948 .. N=300]

PALABRA ID =2 $\Rightarrow$ [0.2038, 0.203948 .. N=300]

PALABRA ID =3 $\Rightarrow$ [0.2038, 0.203948 .. N=300]

PALABRA ID =4 $\Rightarrow$ [0.2038, 0.203948 .. N=300]

...

N

PROMEDIO VECTORES DOCUMENTO = [0.2038, 0.203948 .. N=300]



Otras técnicas de Word Vectors

Otras técnicas para vectorizar palabras (word embeddings):

- GloVe
- FastText

DOC = “El bus rojo ”

El = [0.45, 0.66, 0.12 N=300]

bus = [0.23, 0.34, 0.55 N = 300]

rojo = [0.46, 0.76 N = 300]

Limitaciones:

- Tenemos vectores por cada palabra pero necesitamos agregarlas para representar un texto.
- No sabe lidiar con **palabras que están fuera del vocabulario**.
- No escala a **nuevos idiomas** (esp, africano, frances) .



Modelos de lenguaje

WORD2VEC

BERT



BERT

1 - **Semi-supervised** training on large amounts of text (books, wikipedia..etc).

The model is trained on a certain task that enables it to grasp patterns in language. By the end of the training process, BERT has language-processing abilities capable of empowering many models we later need to build and train in a supervised way.

Semi-supervised Learning Step

Model:



Dataset:




Objective:

Predict the masked word
(language modeling)

2 - **Supervised** training on a specific task with a labeled dataset.

Supervised Learning Step

Model:
(pre-trained
in step #1)



Dataset:


Email message	Class
Buy these pills	Spam
Win cash prizes	Spam
Dear Mr. Atreides, please find attached...	Not Spam

2 tareas.

1. aprender a representar el texto como un vector

2. Clasificar ese vector como spam/no spam

BERT




encoder

The FBI is chasing a criminal on the run .	1
The FBI is chasing a criminal on the run .	2
The FBI is chasing a criminal on the run .	3
The FBI is chasing a criminal on the run .	4
The FBI is chasing a criminal on the run .	5
The FBI is chasing a criminal on the run .	6
The FBI is chasing a criminal on the run .	7
The FBI is chasing a criminal on the run .	8
The FBI is chasing a criminal on the run .	9
The FBI is chasing a criminal on the run .	10

- BERT se compone de **12 encoders en su versión standard** y de **24 encoders en su versión large**.
- **Cada encoder aprende un patrón distinto en el texto**, dependiendo de la **atención que aprender a darle a ciertas palabras**.
- El output de BERT es un **vector de 768 dimensiones por cada token**.
- El **token especial [CLS]** que está al inicio representa al texto completo y sirve de **input para un clasificador**.


BERT tokenizer



BERT trae incorporado un tokenizer que:

1. Divide palabras en dos partes de manera que la segunda se pueda utilizar de nuevo.
(ej. ama + #dos
da +
1. Agregar tokens especiales [CLS] que representa un texto completo y [SEP] para denotar separación si tiene más de una oración.
2. Convertir cada token al índice en el vocabulario.

BERT Entrenamiento [Semi-supervisado]




BERT entrena usando **[MASKING]** que es esconder una palabra aleatoria en el texto y tratar de predecirla.

También aprende a **relacionar oraciones entre sí.**

Vector del token especial **[CLS]** representa al texto completo.


BERT [para clasificación de documentos]



The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .

ejemplo atención en cada encoder de BERT.

BERT para recomendación




Vectorización de texto: BERT (Transformer)

Limitaciones de BERT:


- Complejidad computacional para entrenar en nuevo corpus.
- Se limita largo de los textos a 512 tokens.

Alternativas:

- XLNET
- RoBERTA
- Distill-BERT
- BigBird
- ULMFit
- GPT-3
- GPT-4



El desempeño de modelos de lenguaje depende mucho de la cantidad de parámetros a entrenar.



Supera a todos los modelos anteriores en tareas de:

- Text Summarization
- Question Answering
- Language understanding

entre otros

3. Approach tradicional de recomendación basada en contenido




Movie	Action	Comedy	Adventure	...	...
Wolf of Wall Street	0	1	0		
Fargo	1	1	0	...	...
...					

$$\text{cosine similarity} = S_C(A, B) := \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}},$$

Recomendación basada en contenido

Basado en **características de ítems con los que el usuario ha interactuado** puedo **saber ítems con los que va a interactuar a futuro** que comparta características con ellos.

Tengo que **buscar alguna forma como “agregar” los ítems consumidos por el usuario.**



Características de contenido (texto información del usuario)

- Descripción del perfil del usuario.
- Descripción de ítems.
- Reviews de ítems.
- Tweets de ítems.
- Noticias de ítems.
- Cruce de BD, ej. IMDB.



User profile: soluciona parcialmente “cold start” usuarios que no han participado en la plataforma.

Contenido texto items



Ben Mekler
@benmekler

Crowd at #Venezia76 went absolutely ballistic for #JOKER. Film is dark, sick, twisted. I'm with a crowd of fellow critics right now, running through the streets of Venice just screaming. Hollering. My legs are tired. We've been doing this for hours. Joaquin is an Oscar contender

1:00 PM · Aug 31, 2019 · Twitter for iPhone

67 Retweets 381 Likes



Ben Mekler
@benmekler · 16m

Replying to @benmekler

#JOKER will change superhero cinema forever. Sure to be controversial. The film is a literal riot. I just flipped a car with two of the guys from IndieWire. A Guardian reviewer fell down and we all kept running. I stepped on his hand. REALLY impressed with Todd Phillips

5 46 307

Review Snapshot by PowerReviews

★★★★☆ 4.1 18 reviews Write A Review

Ratings Distribution	Pros	Cons
5 Stars 9	12 Smells/Tastes Great	9 Not Long-Lasting
4 Stars 4	11 Soothing	2 Bad Taste
3 Stars 3	10 Effective	2 Greasy
2 Stars 2	7 Healing	1 Bad Smell
1 Star 0	1 Long Lasting	1 Ineffective

Describe Yourself 9 Brand Buyer 6 Budget Buyer

Best Uses 14 Treat Chapped Lips 9 Daily Use 2 Sun Protection 1 Prevent Wind Burn

Most Liked Positive Review

★★★★★ 5

Pleasantly surprised

I have used the same brand of lip balm for over 5 years and I'm glad I was able to try something new! I loved the smell and it helped my chapped lips. This tube is a little bigger than your typical lip balm, but I found that it was much easier to find in my backpack. I hope they add more flavors (ma...

[Read complete review](#)

vs

Most Liked Negative Review

★★★☆☆ 3

Not the best lip balm

I was looking forward to trying this lip balm, but I was a little disappointed. The color of the tube and the tube itself are cute and different, but the actual lip balm was less than ideal. It didn't last very long on my lips and I didn't really see a change after using it for a couple days. I also...

[Read complete review](#)



Search All Go

The Internet Movie Database

Movies TV News Videos Community IMD



The Matrix (1999)

R 136 min - Action Adventure Sci-Fi - 31 March 1999 (USA)

★★★★★ 8.7/10

Users: (448,475 votes) 3,342 reviews Critics: 248 reviews

Metascore: 73/100 (based on 35 reviews from Metacritic.com)

A computer hacker learns from mysterious rebels about the true nature of his reality and his role in the war against its controllers.

Directors: [Andy Wachowski](#), [Lana Wachowski](#)

Writers: [Andy Wachowski](#), [Lana Wachowski](#)


Stars: [Keanu Reeves](#), [Laurence Fishburne](#) and [Carrie-Anne Moss](#)

¿Cómo funciona?

- Tengo que representar el texto como vectores y hacer uso de estos vectores para la recomendación.

Ejemplos:



- Representar a cada usuario como:
 - vector del texto de todas las reviews que ha hecho.
 - vector del texto de su perfil.
 - vector del texto de los tweets de los ítems con los que ha interactuado
- Representar cada ítem como:
 - vector de texto de sus reviews
 - vector de texto de su descripción



Recomendación

Como **vector del usuario** va a tener las mismas dimensiones que los **vectores de ítems** puedo buscar las más cercanas con alguna métrica de similaridad.

También puedo buscar usuarios cercanos en el espacio y recomendar los ítems con los que otros han interactuado (como filtrado colaborativo).



■ center user

◆ context user

Recomendación basada en contenido (ventajas /desventajas)

ventajas:


- soluciona parte de cold-start de usuarios e ítems.
- es más transparente, “porque te gusta este contenido te recomiendo esto”
- se puede combinar para agregar información adicional al filtrado colaborativo.

desventajas:

- poca diversidad, me va a recomendar más de lo mismo que he consumido.
- **usa vectores de texto pre-entrenados (estáticos) para una tarea distinta que de recomendación.**
- **habría que entrenar el modelo de lenguaje en conjunto con el recomendador.**

En esta clase

1. Repaso de implicit feedback , ALS , BPR y métricas de ranking
2. Concepto de Recomendación basada en contenido
3. Text Mining y NLP
4. Aplicación de Recomendación basada en contenido.



Práctico

https://drive.google.com/file/d/1zgU4X1Hy_WQrcRke4O5fg-WNOrAC5JJs/view?usp=sharing

