

Clase 5:

Sistemas Recomendadores

Vicente Domínguez

Diplomado en Machine Learning Aplicado UC




Programa del Curso

1. Introducción , Recomendación No personalizada , Filtrado Colaborativo (User y Item), Evaluación basada en métricas de error (RMSE, MAE) + **Práctico**.
2. Slope One , Recomendación basada en métodos latentes (Factorización Matricial) + Práctico.
3. Recomendación basada en feedback implícito , Optimización basada en ALS y BPR, Evaluación basada en métricas de ranking, novedad, serendipia + Práctico.
4. Recomendación basada en contenido (text mining , nlp , aplicación) + Práctico.
5. **Recomendación basada en contexto y recomendación híbrida. + Práctico.**
6. Deep Learning para recomendación (texto , imágenes, multimodal, secuencial) + **Práctico**.
7. Reinforcement Learning (Bandits) + Conversational Recsys + **Práctico**
8. Repaso general , dominios de aplicación e investigación reciente , recomendación basada en grafos.

Evaluación

Promedio ejercicios prácticos.

Tiempo para realizarlos. Al final de la clase y luego 1 semana (se entrega en la siguiente clase)



En esta clase

1. Repaso de recomendación basada en contenido.
2. Recomendación contextual.
3. Recomendación híbrida




Repaso




Recomendación basada en contenido

- El filtrado colaborativo funciona bien pero tiene el problema de *cold-start* y *new item*.
- Tenemos **el filtrado basado en contenido** como alternativa.

Recommended Artwork	
 Successfully rated! ★★★★★	it's 81.96% similar to this artwork that you like 



user_profile = {w_1, w_2, ..., w_3} usando
TF-IDF



Doc_1 = {w_1, w_2, ..., w_3}




Doc_2 = {w_1, w_2, ..., w_3}




Doc_3 = {w_1, w_2, ..., w_3}



Doc_n = {w_1, w_2, ..., w_3}



BERT_{BASE}




BERT_{LARGE}

Recomendación basada en contenido

Basado en **características de ítems con los que el usuario ha interactuado** puedo **saber ítems con los que va a interactuar a futuro** que comparta características con ellos.

Tengo que **buscar alguna forma como “agregar” los ítems consumidos por el usuario.**



Recomendación basada en contenido (ventajas /desventajas)

ventajas:

- soluciona parte de cold-start de usuarios e ítems.
- es más transparente, “porque te gusta este contenido te recomiendo esto”
- se puede combinar para agregar información adicional al filtrado colaborativo.

desventajas:

- poca diversidad, me va a recomendar más de lo mismo que he consumido.
- **usa vectores de texto pre-entrenados (estáticos) para una tarea distinta que de recomendación.**
- **habría que entrenar el modelo de lenguaje en conjunto con el recomendador.**

Reflexión

Hasta ahora hemos generado recomendación basada en filtrado colaborativo y contenido.

¿Cómo introducimos información del contexto: día, clima, ubicación, dispositivo, etc..?

¿Cómo podemos combinar contenido, filtrado colaborativo y contexto?

En esta clase

1. Recomendación contextual
2. Recomendación híbrida



1. Recomendación contextual



Contexto

Un factor importante a considerar en las recomendaciones.



Componentes del contexto

1. ¿Estás de humor cuando consumes el ítem?
2. ¿Con quien estoy consumiendo el ítem?
3. ¿Dónde estoy consumiendo el ítem?
4. ¿Cuándo estoy consumiendo el ítem?
5. Ocasión especial



Componentes del contexto

1. ¿Estás de humor cuando consumes el ítem?
2. ¿Con quien estoy consumiendo el ítem?
3. ¿Dónde estoy consumiendo el ítem?
4. ¿Cuándo estoy consumiendo el ítem?
5. Ocasión especial



Componentes del contexto

1. ¿Estás de humor cuando consumes el ítem?
2. ¿Con quien estoy consumiendo el ítem?
3. **¿Dónde estoy consumiendo el ítem?**
4. ¿Cuándo estoy consumiendo el ítem?
5. Ocasión especial



Componentes del contexto

1. ¿Estás de humor cuando consumes el ítem?
2. ¿Con quien estoy consumiendo el ítem?
3. ¿Dónde estoy consumiendo el ítem?
4. ¿Cuándo estoy consumiendo el ítem?
5. Ocasión especial



Componentes del contexto

1. ¿Estás de humor cuando consumes el ítem?
2. ¿Con quien estoy consumiendo el ítem?
3. ¿Dónde estoy consumiendo el ítem?
4. ¿Cuándo estoy consumiendo el ítem?
5. Ocasión especial



Context-aware recommendation (CARS)

Recomendación basada en filtrado colaborativo

Users X Items $\rightarrow$ Ratings (o interacciones)

Recomendación contextual

Users X Items X Context $\rightarrow$ Ratings (o interacciones)



Set de datos de User-Item-Context


User	Item	Who	Where	When	Rating
U1	M1	Kids	Home	Weekend	5
U1	M2	Family	Theater	Weekend	4
U1	M3	Partner	Event	Weekday	5
U2	M1	Friends	Home	Weekend	3
U2	M2	Family	Home	Weekday	4
U3	M2	Kids	Theater	Weekday	2
U3	M3	Partner	Home	Weekend	1
U2	M3	Partner	Home	Weekday	?

Quiz

Hemos aprendido que el contexto es importante para predecir interacciones de usuario-item.

¿Cuál de los siguientes ejemplos NO es información contextual?

- a. Ver una película en el cine.
- b. Ver una película en familia.
- c. El largo de la película.
- d. Tu estado de humor al ver la película.
- e. Ir a un restaurante en la mañana.
- f. Ir a un restaurant en la tarde-noche.




Tipos de recomendación contextual

1. Contextual pre-filtering
2. Contextual post-filtering
3. Contextual modeling



Contextual pre-filtering




ERROR COMÚN:

ESCOGER UN CONTEXTO DEMASIADO ESPECÍFICO.

BUEN CONTEXTO:


- DIA / NOCHE
- INVIERNO
- LOCAL DE MACUL

Contextual post-filtering



IGNORAMOS EL
CONTEXTO ANTES DE
HACER LA
RECOMENDACION

Contextual modeling



APRENDE VECTORES:

- USUARIO
- ITEM
- CONTEXTO


INCORPORA EL CONTEXTO
EN EL MODELO

Deviation-based context-aware matrix factorization

¿Cuál es la desviación de los ratings?

Contextual rating deviation (CRD).

Ver la desviación del rating dados los distintos contextos.



Deviation-based context-aware matrix factorization



Context	Location	Time	Who
C1	Home	Weekend	Family
C2	Home	Weekend	Friend
C3	Home	Weekday	Family
C4	Home	Weekday	Friend
C5	Theater	Weekend	Family
C6	Theater	Weekend	Friend
C7	Theater	Weekday	Family
C8	Theater	Weekday	Friend

Deviation-based context-aware matrix factorization

Context	Location	Time	Who
C1	Home	Weekend	Family
C8	Theater	Weekday	Friend
CRD(Dim)	0.8	-0.2	0.1

Usuarios han dado

- +0.8 rating para contexto de Cine comparado con Hogar
- -0.2 rating menos para Dia de semana que para Fin de semana.
- +0.1 rating cuando ve la película con Amigos que con Familia

Deviation-based context-aware matrix factorization

The diagram illustrates the equation for deviation-based context-aware matrix factorization, with various components annotated by colored arrows:

$$r_{uic1,c2,\dots} = \mu + b_{\mu} + b_i + P_U^T q_i + \sum_{j=1}^N CRD(C_j)$$

- Avg Rating** (red arrow) points to μ .
- User Bias** (blue arrow) points to b_{μ} .
- Item Bias** (blue arrow) points to b_i .
- User-item interaction** (red arrow) points to $P_U^T q_i$.
- Contextual Rating** (green arrow) points to the left side of the equation, $r_{uic1,c2,\dots}$.
- Contextual Rating Deviation** (green arrow) points to the summation term, $\sum_{j=1}^N CRD(C_j)$.

Deviation-based context-aware matrix factorization (Tipos)

$$r_{uic1,c2,\dots} = \mu + \sum_{j=1}^N CRD(C_j, u) + b_i + P_U^T q_i$$

Variación de ratings de **Usuarios** dependiendo del contexto (C_j)

$$r_{uic1,c2,\dots} = \mu + b_\mu + \sum_{j=1}^N CRD(C_j, i) + P_U^T q_i$$


Variación de ratings de **Items** dependiendo del contexto (C_j)

2. Recomendación híbrida




¿Para qué me puede servir combinar varios recomendadores?

- Un recomendador puede tener mejor desempeño en ciertos patrones y otros no.
- Basado en contenido al no sufrir de cold start se podría combinar con filtrado colaborativo



Tipos de recomendación híbrida.




Tipos de recomendación híbrida.

1. **Monolítico:** corre uno a uno varios recomendadores y va filtrando los resultados en un determinado orden.
2. **Mix de recomendadores:** corre varios recomendadores, retorna todos los scores (normalizados) y los ordena de mayor a menor.
3. **Ensamble:** corre varios recomendadores y combina o mezcla su resultado en una sola recomendación.

1. Monolítico


Contiene partes o módulos con diferentes tipos de recomendadores. Por ejemplo podemos usar contenido para encontrar ítems similares content-wise y luego sobre ese subset de ítems aplicar filtrado colaborativo.



2. Mix de recomendadores

Retorna simplemente la UNIÓN de todos los resultados y ordena por score.

Por ejemplo se toman algoritmos de recomendación personalizada, obtiene un score normalizado y retorna resultados ordenados.



```
resultado_ALGO1 = []  
res_ALGO2  
RES_ALGO3  
  
for rec in [algo1, algo2 , algo3]:  
    rec(catalogo)  
    res = [[i1 , score ] , [i2 , score ] ....]  
    resultado.extend(res)  
  
resultado.sort(by = score) [0:N]
```



3. Ensamble

Ejemplo:

Si tienes dos recomendadores en producción, por ejemplo uno basado en contenido y otro en filtrado colaborativo, ejecuta ambos de manera simultánea y luego combina los resultados.


Collaborative
Filtering?



Content Based?

NOTA:

La principal diferencia entre un ensamble y un recomendador mixto es que el ensamble en el resultado no muestra las predicciones de todos los recomendadores sino que los combina en una sola, en cambio el sistema mixto siempre retorna todo y luego ordena.



Ensamble

The image shows a Quora profile for Xavier Amatriain on the left and a video player on the right. The profile includes a photo, a 'Follow' button, and statistics: 44 SlideShares, 10,289 Followers, and 0 Clipboards. His location is San Francisco Bay Area, United States, and he is a VP Engineering at Quora. His bio mentions he builds teams to tackle complex problems and is currently leading the Engineering team at Quora. The video player on the right shows a slide titled '6. EVERYTHING IS AN ENSEMBLE' with the Quora logo in the bottom right corner. The video is titled 'Recsys 2016 tutorial: Lessons learned from building real-life recommender systems' and has 3,781 views. The video player interface includes a progress bar at 25 of 46 and an 'Embed' button.

“If you’re a start up and want to get into recommender systems, you should start with matrix factorization and add recommenders to create an ensemble recommendation system”

Xavier Amatriain, Netflix

Ensamble


Tipos de ensambles:

1. Votación entre distintos algoritmos de recomendación.
2. Utilizar heurísticas para decidir qué algoritmo de recomendación utilizar.
3. Pesos (aprendidos o como meta-parámetro) asignado a cada recomendador.
4. Feature ensemble: agrega features adicionales a un algoritmo de recomendación.


Ensamble

Tipos de ensambles:

- 1. Votación entre distintos algoritmos de recomendación.**
2. Utilizar heurísticas para decidir qué algoritmo de recomendación utilizar.
3. Pesos (aprendidos o como meta-parámetro) asignado a cada recomendador.
4. Feature ensemble: agrega features adicionales a un algoritmo de recomendación.



Ensamble basado en votación



Ensamble


Tipos de ensambles:

1. Votación de rating entre distintos algoritmos de recomendación.
- 2. Utilizar heurísticas para decidir qué algoritmo de recomendación utilizar.**
3. Pesos (aprendidos o como meta-parámetro) asignado a cada recomendador.
4. Feature ensemble: agrega features adicionales a un algoritmo de recomendación.



Ensamble basado en heurísticas

Para usuarios que han dado menos de 10 ratings, utilizar basado en contenido, en caso contrario usar filtrado colaborativo.




Ensamble

Tipos de ensambles:


1. Votación de rating entre distintos algoritmos de recomendación.
2. Utilizar heurísticas para decidir qué algoritmo de recomendación utilizar.
- 3. Pesos (aprendidos o como meta-parámetro) asignados a cada recomendador.**
4. Feature ensemble: agrega features adicionales a un algoritmo de recomendación.

Ensamble basado en pesos



Ensamble basado en pesos entregados por un método de aprendizaje

Netflix Prize uso un ensemble de múltiples métodos (FM y RBM)



The screenshot shows the 'Netflix Prize Leaderboard' with a navigation bar containing links: Rules, Leaderboard, Register, Update, Submit, and Download. The title 'Leaderboard' is in large blue font, followed by 'Display top 20 leaders.' The table below lists the top two teams:

Rank	Team Name	Best Score	% Improvement	Last Submit Time
1	The Ensemble	0.8553	10.10	2009-07-26 18:38:22
2	BellKor's Pragmatic Chaos	0.8554	10.09	2009-07-26 18:18:28

A red banner at the bottom of the table states: 'Grand Prize - RMSE <= 0.8563'.


pesos ahora son funciones $f(u,i)$ y $g(u,i)$
que aprenden los pesos para cada
recomendador.

Ensamble

Tipos de ensamble:

1. Votación de rating entre distintos algoritmos de recomendación.
2. Utilizar heurísticas para decidir qué algoritmo de recomendación utilizar.
3. Pesos (aprendidos o como meta-parámetro) asignados a cada recomendador.
4. **Feature ensemble: agrega features adicionales a un algoritmo de recomendación.**

Factorization machines [1/2]



Factorization machines [2/2]

$$\hat{y}(\mathbf{x}) := w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j$$

Coeficientes de
regresión de la
iesima variable

Factorización
Matricial
User - Item

Interacción
entre features
 x_i y x_j

Implementación de Factorization Machines en AWS



AWS Machine Learning Blog

Extending Amazon SageMaker factorization machines algorithm to predict top x recommendations

by Zohar Karnin and Rama Thamman | on 05 APR 2019 | in [Amazon SageMaker](#), [Artificial Intelligence](#) | [Permalink](#) | [Comments](#) | [Share](#)



<https://aws.amazon.com/es/blogs/machine-learning/extending-amazon-sagemaker-factorization-machines-algorithm-to-predict-top-x-recommendations/>

Práctico

<https://drive.google.com/file/d/1ws0q2hRWHIzaC1Kux0LXJVjdkzAqy4YQ/view?usp=sharing>

