

Clase 7:

Sistemas Recomendadores

Vicente Domínguez

Diplomado en Machine Learning Aplicado UC



Programa del Curso

1. Introducción , Recomendación No personalizada , Filtrado Colaborativo (User y Item), Evaluación basada en métricas de error (RMSE, MAE) + **Práctico**.
2. Slope One , Recomendación basada en métodos latentes (Factorización Matricial) + Práctico.
3. Recomendación basada en feedback implícito , Optimización basada en ALS y BPR, Evaluación basada en métricas de ranking, novedad, serendipia + Práctico.
4. Recomendación basada en contenido (text mining , nlp , aplicación) + Práctico.
5. Recomendación basada en contexto y recomendación híbrida. + Práctico.
6. Deep Learning para recomendación (texto , imágenes, multimodal, secuencial) + Práctico.
7. **Reinforcement Learning (Bandits) + Práctico**
8. Repaso general , revisión notas/calificaciones finales y dominios de aplicación e investigación reciente.

En esta clase



1. Repaso de deep learning para recomendación
2. Aprendizaje reforzado
3. Práctico aprendizaje reforzado.



Repaso




Deep Learning




Imágenes en recomendaciones


- [VBPR: Visual Bayesian Personalized Ranking from Implicit Feedback](#) [He and McAuley, 2016]
- Utiliza CNN para obtener características visuales
- Utilizan embeddings de usuarios e ítems
- Pérdida BPR (pairwise)




MFCC



Señal de audio




Espectrograma




MFCC


DL en Van den Oord et al (2013)



wav2vec RNN




transformers wav2vec: convertir audio a embedding.




Reflexión

¿Cómo podemos simular el comportamiento de un usuario?



En esta clase

1. Aprendizaje reforzado.
2. Recomendación basada en aprendizaje reforzado.
3. Práctico recomendación basada en aprendizaje reforzado contextual.



Tipos de aprendizaje en recomendación

Aprendizaje Supervisado

Aprende de feedback dado por el usuario:

- Ratings
- Interacciones
- Clasificación

Aprendizaje No Supervisado

Caracteriza a usuarios e ítems sin etiquetas.

Ejemplo: clustering.

Aprendizaje Reforzado

Aprende de interacción en tiempo real del usuario con la plataforma/entorno.
Quiero **optimizar algo que no se puede expresar en una función de pérdida.**

**RESTAURANTE NUEVO
VIETNAM**



Mayor grado de exploración

**RESTAURANTE NUEVO
CHINA**



Grado de exploración intermedio

**RESTAURANTE DE SIEMPRE
PERÚ**




Baja exploración



Dilema: Exploración vs Explotación

APRENDIZAJE REFORZADO

APRENDIZAJE POR PRUEBA Y ERROR.
EXPLORAR ACCIONES NUEVAS APOSTANDO POR UNA
RECOMPENSA A COSTA DE PERDER TIEMPO Y RECURSOS.



Reinforcement Learning . Atari Breakout



Aprendizaje reforzado en sistemas recomendadores.

Manejo de la incertidumbre.

COLD START (USUARIOS E ÍTEMS)

CAMBIO DINÁMICO EN LAS PREFERENCIAS DE LOS USUARIOS

CAMBIO DINÁMICO EN EL CATÁLOGO DE PRODUCTOS



CAMBIOS EN EL CONTEXTO DE USO DE LA PLATAFORMA. (WEB, TV, MOVIL)

INFORMACIÓN CAMBIA CONSTANTEMENTE (ej. Noticias).

Trade-off: Exploración y Explotación en recomendación

EXPLOTACIÓN:

¿SEGUIMOS
RECOMENDANDO BASADO
EN INFORMACIÓN
HISTÓRICA DEL USUARIO EN
LA PLATAFORMA?

RIESGO: ABURRIMIENTO DE
RECIBIR SIEMPRE LAS
MISMAS
RECOMENDACIONES.



EXPLORACIÓN:

¿RECOMENDAMOS
CONTENIDO DISTINTO A SUS
PREFERENCIAS HISTÓRICAS?

RIESGO: RECOMENDAR UN
CONTENIDO MUY ALEJADO
DE SUS PREFERENCIAS QUE
PUEDE HACERLO SALIR. .

Trade-off: Exploración y Explotación en recomendación

Mayor grado de exploración

Grado de exploración intermedio

Bajo grado de exploración



EXPLORAR NUEVOS
LOCALES DE COMIDA

POSIBLE
RECOMPENSA A
LARGO PLAZO.
DIVERSIFICACIÓN.



EXPLOTAR LO QUE
SIEMPRE HE VISTO


RECOMPENSA DE
CORTO PLAZO
QUE DECAE CON EL
TIEMPO

Balancear exploración y explotación es importante para aprender una forma de tomar mejores decisiones en caso de incerteza.



Conceptos claves en Aprendizaje Reforzado (1 / 2)

- **Environment:** es el mundo que reacciona a acciones hechas por agente. Ej Plataforma.
- **State:** parámetros que describen el estado actual. Ej. screen actual de un juego, screen de una página web.
- **Agent:** es el jugador que ejecuta acciones y aprende de ellas al interactuar con el entorno.
- **Action:** un agente puede seleccionar una acción de un set de acciones.
- **Step:** una vez que el agente hace una acción sobre el entorno el estado cambia a otro nuevo. Este cambio se llama step.



Conceptos claves en aprendizaje reforzado (2 / 2)

- **Reward:** dependiendo de la acción que toma el agente, el entorno le da un premio o un castigo.
- **Target:** lo que el agente busca maximizar al terminar un episodio.
- **Policy:** lo que aprende el modelo donde dado un estado nuevo me predice que acción tomar.
- **Episode:** conjunto de pasos que se define dependiendo del problema, en videojuegos puede ser una partida.



MULTI-ARMED BANDITS.

Acción (at):
¿Qué máquina juego?



1



2



3



Recompensa (rt):
Dinero \$

Reglas:
Tengo un número limitado de intentos (fichas).

Objetivo:
Maximizar ganancia futura.

MULTI-ARMED BANDITS.

Tenemos cada tragamonedas tiene una distribución de rewards por detrás que **no conozco**.
Tengo que estimar la posible reward de cada máquina con el mínimo de juegos.



1



2



3

Reglas

- Número limitado de intentos
- Acción: Puedo jugar a la máquina 1, 2 o 3.
- Feedback se observa solo si juego en la máquina.

Objetivo:

Maximizar mi ganancia

Jugar a máquina 1, 2 o 3 son las K posibles acciones

¿Cómo medir el éxito?

Objetivo

Maximizar
suma de reward

Maximizar reward
promedio

Maximizar % de
acciones correctas

Disminuir
arrepentimiento


Definición

Sumar el máximo \$ posible

Sumar máximo \$ promedio

Escoger la acción que me da mayor ganancia


Regret de tomar malas acciones que disminuyen
mi ganancia.



Veamos un caso práctico

Multi-Armed Bandits Activity

Try to get the most coins that you can!



Juguemos al tragamonedas y veamos cómo nos va:

http://apbarraza.com/bandits_activity/



Discusión

¿Qué estrategia tomaron?

¿Cómo les fué?

¿Qué hace que el nivel hard hace que sea más difícil que el resto?





Juguemos



MÁQUINA 1

\$5.000



MÁQUINA 2

1

2

3


4

5

6

7

8



Juguemos



MÁQUINA 1

\$5.000



MÁQUINA 2

\$ 0

1

2

3

4

5

6

7

8

Juguemos



MÁQUINA 1



MÁQUINA 2

1

\$5.000

2

\$ 0

3

\$5.000

4

5

6

7

8

Juguemos



MÁQUINA 1

1

\$5.000

2

\$5.000

3

\$5.000

4

5

6


7

8



MÁQUINA 2

\$ 0



Juguemos



MÁQUINA 1



MÁQUINA 2

1

\$5.000

2

\$5.000

3

\$5.000

4

\$ 0

5

\$ 0

6

\$ 0

7

8

Juguemos

JUGUEMOS
SOLO A LA
MÁQUINA 1
....

- 1
- 2
- 3
- 4
- 5
- 6
- 7
- 8



MÁQUINA 1

- \$5.000
- \$5.000
- \$5.000
- \$5.000
- \$5.000
- \$5.000
- \$5.000
- \$5.000



MÁQUINA 2

- \$ 0
- \$ 0
- \$ 0
- \$ 0
- \$ 0
- \$ 0
- \$ 0
- \$ 0

\$ ganancia total \$ 40.000

Veamos el resultado...



MÁQUINA 1 PAGA
\$5.000 SIEMPRE

MÁQUINA 2 PAGA
\$60.000 EL 50% DE LAS
VECES
~ \$30.000 POR JUEGO
MAQUINA ÓPTIMO.

ENSEÑANZA:
NOS FALTÓ MÁS
EXPLORACIÓN ANTES DE
QUEDARNOS CON LA
MÁQUINA 1....

MÁQUINA 1
1
2
3
4
5
6
7
8

MÁQUINA 2
\$5.000
\$0
\$60.000
\$0
\$0
\$60.000
\$0
\$60.000
ganancia potencial: \$240.000

ganancia potencial: \$40.000

si exploro mucho, a corto plazo voy a obtener menos ganancias.

TRADE-OFF:

EXPLORACIÓN / EXPLOTACIÓN

CORTO PLAZO / LARGO PLAZO



explotar: me puede hacer perder la máquina más óptima si yo no tengo la información suficiente para tomar la mejor decisión.

En el [largo plazo](#) puedo perder porque no obtuve la suficiente información.

¿QUÉ ESTRATEGIAS NOS PUEDEN AYUDAR A ESCOGER LA MEJOR ACCIÓN?

- **Greedy exploration for n steps**
- **Epsilon greedy**
- **Decreasing epsilon greedy**
- **Upper confidence bound (UCB)**



Explorar y luego explotar (greedy exploration)

EXPLORAR

ACCIÓN ALEATORIA

N PASOS DE EXPLORACIÓN

EXPLOTAR

MEJOR ACCIÓN CONOCIDA

[GREEDY ACTION]

ESCOGER LA ACCIÓN CON
VALOR DE RECOMPENSA
ESPERADA MÁS ALTA.

$Q_t(a)$: función a la que nosotros le damos la acción y retorna cual es el valor que creemos que esa acción tendrá en ese momento t .

Forma sencilla de estimarlo (promedio de las rewards observadas para cada acción

$Q(0)$, $Q(1)$, $Q(2)$ etc...)

$Q_t(a) = \text{sum}(\text{rewards}) / N$ pasos exploración

$Q_t(a) = \text{reward promedio exploración para acción } a$

Explorar y luego explotar: estrategias

EXPLORAR

EXPLOTAR

ACCIÓN ALEATORIA

MEJOR ACCIÓN CONOCIDA

N PASOS DE EXPLORACIÓN

[GREEDY ACTION]

ESCOGER LA ACCIÓN QUE
LE VA MEJOR EN ESE
MOMENTO

T
total
pasos

Explora cada
acción una vez

Explorar K pasos
K = número de acciones

EXPLOTAR
T - K
Pasos

1

Explora acciones
aleatoriamente
durante una
proporción (e) de T

Explorar $K * e$
donde $0 < e < 1$

EXPLOTAR
T - $K * e$
Pasos

2


Sistemas recomendadores basados en bandits



Pero

¿Qué pasa si cuando exploramos las acciones justo nos fue mal?

En este caso explotaremos eternamente una acción que no es óptima.




Epsilon Greedy

Un epsilon

- **más grande** implica mayor exploración.
- **más chico** implica mayor explotación.

Tenemos que escoger epsilon (ϵ) entre 0 y 1



Acción random

Explotar acción con mayor reward esperado.

(mayor reward en promedio).

$Q(A) = \text{avg}(\text{reward})$

Curva de aprendizaje de epsilon greedy

10 posibles acciones

Azul: Epsilon greedy (epsilon=0.1)

Rojo: Epsilon greedy (epsilon=0.01)



Verde: Epsilon greedy (epsilon=0)

Epsilon mayor (0.1) tiene más chances de explorar más y por ende tiene una recompensa a largo plazo.

Epsilon de 0.01 mejora más lento porque explota mucho y explora pocas veces.


Pero en algún momento el modelo con epsilon de 0.01 va a superar al de 0.1.

Epsilon 0 explota siempre, por lo tanto nunca aprende. Reward queda casi constante.



Estrategia de Epsilon decreciente

valor de epsilon




Podemos tomar una estrategia donde:

- Comenzamos con un epsilon grande que explora más.
- Una vez que exploramos lo suficiente lo disminuimos en el tiempo para aumentar la explotación.


Aplicación 1: Ofertas diarias

Explore then Exploit meets Recommender Systems (RecSys)



[1] A. Lacerda, R. Santos, et al. 2015. Improving daily deals recommendation using explore-then-exploit strategies.

Aplicación 2: Epsilon Greedy + RecSys



ACTIONS


- COLLABORATIVE FILTERING
- MATRIX FACTORIZATION ALS
- MATRIX FACTORIZATION BPR

Upper confidence bound

3 posibles acciones (a_1 , a_2 , a_3)

Acción 3 ya es subóptima porque su intervalo hacia arriba es peor que el máximo intervalo de Acción 1 y 2.

En este caso escogemos la acción 1, que tiene la mayor recompensa esperada en el intervalo de arriba.



UCB

Deterministic policy: UCB2.

Parameters: $0 < \alpha < 1$.

Initialization: Set $r_j = 0$ for $j = 1, \dots, K$. Play each machine once.

Loop:

1. Select machine j maximizing $\bar{x}_j + a_{n,r_j}$, where $\bar{x}_j$ is the average reward obtained from machine j , a_{n,r_j} is defined in (3), and n is the overall number of plays done so far.
2. Play machine j exactly $\tau(r_j + 1) - \tau(r_j)$ times.
3. Set $r_j \leftarrow r_j + 1$.

Variantes

Variants !

Mortal Bandits

Combinatorial Bandits

Dueling Bandits

Adversarial Bandits

Non-Stationary Bandits

Dependent Arms

STOCHASTIC

INDEPENDENT

Reward

DO NOT CHANGE

Distributions

Multiple Play Bandits



A



B



C

Infinite

K actions

Continuous

- Maximize total payoff.

- Play for T trials.

Infinite

- Feedback is observed only for played arm.

Full Feedback

and many more...




Contextual bandits

En este caso la recompensa depende de:

- la acción
- el contexto


contexto puede ser:

- día de la semana
- hora
- temporada
- etc...



LinUCB: Caso de Yahoo! Web Page

Goal: Maximize user click feedback



for LinUCB
Online News
Recommendation

[1] L. Li, W. Chu, J. Langford, and R. Schapire. 2010. A contextual-bandit approach to personalized news article recommendation.


Contextual bandits [LinUCB]

LinUCB: incorpora combinaciones lineales de features de usuarios a las rewards esperadas de los bandits.

Posibles acciones (a_1 , a_2 , a_3)



a_1



a_2



a_3

Feature contextual (edad)



$x = [1,0]$



$x = [0,1]$


Contextual bandits [LinUCB]

LinUCB: incorpora combinaciones lineales de features de usuarios a las rewards esperadas de los bandits.

Posibles acciones (a_1 , a_2 , a_3)



a_1



a_2



a_3



$x = [1,0]$


Contextual bandits [LinUCB]

LinUCB: incorpora combinaciones lineales de features de usuarios a las rewards esperadas de los bandits.

Posibles acciones (a_1 , a_2 , a_3)



a_1



a_2



a_3



$x = [1, 0]$


Contextual bandits [LinUCB]

LinUCB: incorpora combinaciones lineales de features de usuarios a las rewards esperadas de los bandits.

Posibles acciones (a_1 , a_2 , a_3)



a_1



a_2



a_3



$x = [0,1]$


Contextual bandits [LinUCB]

LinUCB: incorpora combinaciones lineales de features de usuarios a las rewards esperadas de los bandits.

Posibles acciones (a_1 , a_2 , a_3)



a_1



a_2



a_3



$x = [0,1]$

Contextual bandits [LinUCB]

$$\hat{Q}_t(x_t, a) = x_t^T \cdot \hat{\theta}_a$$

Recompensa esperada (Q) depende del **contexto** y de la **acción**.

theta a hat = recompensa esperada para ese segmento de usuarios.


XtT = vector de features

Ahora la recompensa es la combinación lineal de ambos.

Posibles acciones (a1, a2, a3)



a_1



a_2



a_3

Feature contextual (edad)



$x = [1, 0]$



$x = [0, 1]$



Carousel Personalization in Music Streaming Apps with Contextual Bandits




Carousel personalization

Desafíos:


En qué orden mostrar las listas (made for you , recommended playlists , generos).

En qué orden mostrar los elementos dentro de cada lista.

Feedback del usuario viene al contar los clicks que le da a los ítems que están dentro de una lista (feedback en cascada).




- **Contextual multi-armed bandit** problem with **multiple plays**
 - 1 arm = 1 playlist
 - Recommend L playlists / day to each user
- Users are logged in and we know their **listening history** and **musical preferences**
- We don't know which playlists were actually seen by users:
 - Due to the swipeable structure
 - Integrated in the framework via a **cascade feedback model**
- Positive feedback (streams) only available at the end of the day
 - **Delayed batch feedback**



Offline evaluation:

- Compare several **popular bandit algorithms**:
 - Cluster-based **semi-personalized** strategies
 - **Fully-personalized** contextual strategies
- Compare policies with and without the proposed **cascade** feedback model for arms updates
 - Integrating that some playlists might not be seen by users
- On a carousel-based playlist recommendation task using a **Deezer offline dataset**
 - 974 960 real Deezer users
 - Context vectors summarizing musical preferences
 - Users are also clustered in 100 groups
 - 862 curated playlists, among the most popular ones
 - Estimated display-to-stream probabilities for each user-playlist pair (*see paper*)



Top-12 playlist recommendation: expected cumulative regrets of policies over 100 simulated rounds. The empirical gain of *ts-seg-pessimistic* w.r.t. others is statistically significant at the 1% level (p -value < 0.01).


Miden el regret (arrepentimiento) de cada estrategia

Online evaluation:

- Playlist recommendation on the **actual Deezer app**
 - Using some of the best policies from offline experiments
 - Compared to an internal baseline (no bandit)

- **Large-Scale A/B test** on Deezer's homepage
 - Performed in February 2020
 - Identified policies with best display-to-stream rates on the app

- Results tend to confirm:
 - The superiority of the proposed **contextual bandit framework** for large-scale carousel-based personalization
 - The empirical benefits of integrating:
 - **semi-personalized** strategies
 - a **cascade** model for arms updates



Online A/B test evaluation: relative display-to-stream gains w.r.t. random-top-100 baseline. Differences are statistically significant at the 1% level (p-value <0.01).

Práctico final

https://drive.google.com/file/d/1tiBqpE_B6lVv81G6B5X_0p_VmvA8yjnV/view?usp=sharing

