

Clase 8:

Sistemas Recomendadores

Vicente Domínguez

Diplomado en Machine Learning Aplicado UC



Programa del Curso

1. Introducción , Recomendación No personalizada , Filtrado Colaborativo (User y Item), Evaluación basada en métricas de error (RMSE, MAE) + **Práctico**.
2. Slope One , Recomendación basada en métodos latentes (Factorización Matricial) + Práctico.
3. Recomendación basada en feedback implícito , Optimización basada en ALS y BPR, Evaluación basada en métricas de ranking, novedad, serendipia + Práctico.
4. Recomendación basada en contenido (text mining , nlp , aplicación) + Práctico.
5. Recomendación basada en contexto y recomendación híbrida. + Práctico.
6. Deep Learning para recomendación (texto , imágenes, multimodal, secuencial) + Práctico.
7. Reinforcement Learning (Bandits) + Práctico
8. Repaso general , revisión notas/calificaciones finales y dominios de aplicación e investigación reciente.

En esta clase


1. Cierre de calificaciones
2. Repaso general
3. Aplicaciones de sistemas de recomendación




Repaso general



Esquema de recomendación



Recomendación no personalizada, semi-personalizada y personalizada.




Recomendación personalizada

1. Filtrado colaborativo



Filtrado Colaborativo basado en Usuarios

- **Objetivo:** buscar a usuarios similares y recomendar usando una suma ponderada con una métrica de similaridad



<https://www.slideshare.net/tantrieuf31/introduction-to-recommendation-systems>

Filtrado Colaborativo basado en Items

- En vez de calcular la similaridad entre usuarios, calcula la similaridad entre ítems para generar las recomendaciones
- Sub tareas
 - Calcular similaridad entre ítems *co-rated* (co-consumidos)
 - Calcular predicciones

USER-BASED




Figure 1: The Collaborative Filtering Process.

ITEM-BASED





Figure 2: Isolation of the co-rated items and similarity computation


Filtrado colaborativo (resumen)

Basada en usuario



Slope One: intuición


- Diferencias de *ratings* entre pares de ítems generan una buena predicción



Recomendación personalizada


2. Recomendación basada en métodos latentes

Recomendación basada en factores latentes (factorización matricial SVD).



Factorización Matricial – Vectores Latentes

- Los vectores latentes capturan atributos de los ítems y si a los usuarios les gustan dichos atributos



Factorización Matricial - *FunkSVD*

- Una solución es el modelo *FunkSVD* y consiste en solucionar el siguiente modelo de optimización (<https://sifter.org/simon/journal/20061211.html>)

$$\min_{p^*, q^*} \sum_{(u,i) \in K} (r_{ui} - q_i^T \cdot p_u)^2 + \lambda(\|q_i\|^2 + \|p_u\|^2)$$

donde

r_{ui} : rating que asignó el usuario u al ítem i

q_i : vector latente del ítem i

p_u : vector latente del usuario u

λ : constante de regularización

OPTIMIZACIÓN:

- Descenso de gradiente

Métricas de error (predicción de rating)

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

$\sim 0 \rightarrow \text{mejor}$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Recomendación personalizada

3. Recomendación basada feedback implícito

Retroalimentación Implícita o Implicit Feedback

- Hu, Y., Koren, Y., & Volinsky, C. (2008) modificaron el modelo de SVD para incluir *feedback* implícito

Binarización de los datos

$$p_{ui} = \begin{cases} 1 & \text{si } r_{ui} > 0 \\ 0 & \text{si } r_{ui} = 0 \end{cases}$$

Ej. lo compra o no lo compra?
interacción?

Función de confianza

$$c_{ui} = 1 + \alpha r_{ui}$$

Ej. - dwell time (más tiempo ,
mayor score)
- monto \$, UF

Función de pérdida (Implicit Funk SVD)

$$\min_{x^*, y^*} \sum_{u, i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda (||x_u||^2 + ||y_i||^2)$$

Optimización de recomendación basada en factorización matricial con feedback implícito

1. Alternate Least Squares (ALS).
2. Bayesian Personalized Ranking (BPR):

REFLEXIÓN:

El único algoritmo de recomendación para trabajar con feedback implícito son los basados en factores latentes. (ej. factorización matricial)




Métricas de ranking

Sirven evaluar el recomendador como queremos que ordene los resultados , más que predecir ratings.


- **precision@k**: relevantes encontrados / K
- **recall@k**: relevantes encontrados en los top k / total relevantes
- **F1@K**: media armónica entre p y r.
- **MRR**: 1 / primer relevante.
- **MAP**: average precision promedio de todos los usuarios.
- **ndcg@k**: mide la ganancia de la posición del ítem relevante.
- **Cobertura**: mide que porcentaje del catálogo se está recomendando.
- **Diversidad**: mide la variedad de los items recomendados.

Recomendación personalizada

4. Recomendación basada contenido (texto)



user_profile = {w_1, w_2, ..., w_3} usando
TF-IDF




Doc_1 = {w_1, w_2, ..., w_3}


Doc_2 = {w_1, w_2, ..., w_3}

Doc_3 = {w_1, w_2, ..., w_3}

Doc_n = {w_1, w_2, ..., w_3}

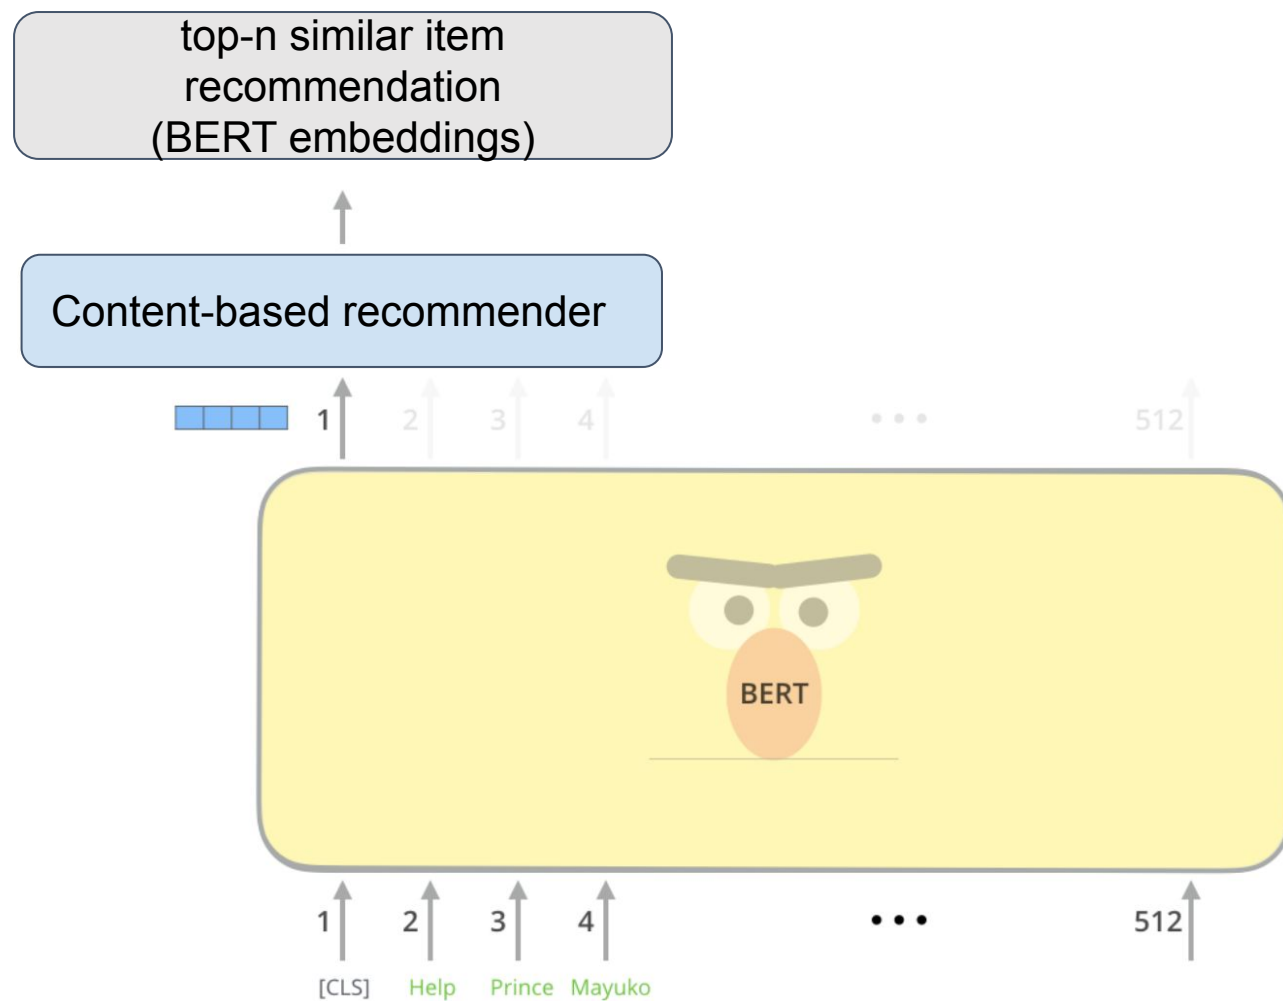


BERT_{BASE}



BERT_{LARGE}


BERT para recomendación



Recomendación basada en contenido

Basado en **características de ítems con los que el usuario ha interactuado** puedo **saber ítems con los que va a interactuar a futuro** que comparta características con ellos.



Tengo que **buscar alguna forma como “agregar” los ítems consumidos por el usuario.**



Recomendación

Como **vector del usuario** va a tener las mismas dimensiones que los **vectores de ítems** puedo buscar las más cercanas con alguna métrica de similaridad.

También puedo buscar usuarios cercanos en el espacio y recomendar los ítems con los que otros han interactuado (como filtrado colaborativo).



■ center user

◆ context user

Recomendación personalizada

5. Recomendación contextual



Context-aware recommendation (CARS)

Recomendación basada en filtrado colaborativo

Users X Items $\rightarrow$ Ratings (o interacciones)

Recomendación contextual

Users X Items X Context $\rightarrow$ Ratings (o interacciones)

CONTEXTO SE PUEDE:

- FILTRAR ANTES DE RECOMENDAR
- DESPUÉS DE RECOMENDAR
- INCLUIRLO EN LA RECOMENDACIÓN



Recomendación personalizada


6. Recomendación híbrida



Tipos de recomendación híbrida.

1. **Monolítico:** corre uno a uno varios recomendadores y va filtrando los resultados en un determinado orden basado en ciertas heurísticas.
2. **Mix de recomendadores:** corre varios recomendadores, retorna todos los scores (normalizados) y los ordena de mayor a menor.
3. **Ensamble:** corre varios recomendadores y combina o mezcla su resultado en una sola recomendación.

Factorization machines [1/2]



Factorization machines [2/2]

$$\hat{y}(\mathbf{x}) := w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j$$

Coeficientes de
regresión de la
iesima variable



Factorización
Matricial
User - Item

Interacción
entre features
 x_i y x_j

Recomendación personalizada


7. Recomendación basada en deep learning

¿Por qué deep learning?



Imágenes en recomendaciones

- [VBPR: Visual Bayesian Personalized Ranking from Implicit Feedback](#) [He and McAuley, 2016]
- Utiliza CNN para obtener características visuales
- Utilizan embeddings de usuarios e ítems
- Pérdida BPR (pairwise)



Imágenes en Recomendaciones





Recomendación personalizada

8. Recomendación basada en aprendizaje reforzado



APRENDIZAJE REFORZADO

APRENDIZAJE POR PRUEBA Y ERROR.
EXPLORAR ACCIONES NUEVAS APOSTANDO POR UNA
RECOMPENSA A COSTA DE PERDER TIEMPO Y RECURSOS.



Trade-off: Exploración y Explotación en recomendación

Mayor grado de exploración

Grado de exploración intermedio

Bajo grado de exploración



**EXPLORAR NUEVOS
LOCALES DE COMIDA**

POSIBLE
RECOMPENSA A
LARGO PLAZO.
DIVERSIFICACIÓN.



**EXPLOTAR LO QUE
SIEMPRE HE VISTO**

RECOMPENSA DE
CORTO PLAZO
QUE DECAE CON EL
TIEMPO

Sistemas recomendadores basados en bandits




Epsilon Greedy

Tenemos que escoger epsilon (ϵ) entre 0 y 1

Un epsilon

- **más grande** implica mayor exploración.
- **más chico** implica mayor explotación.



Acción random


Explotar acción con mayor reward esperado.

(mayor reward en promedio).

$Q(A) = \text{avg}(\text{reward})$


Aplicación 1: Ofertas diarias

Explore then Exploit meets Recommender Systems (RecSys)



[1] A. Lacerda, R. Santos, et al. 2015. Improving daily deals recommendation using explore-then-exploit strategies.

Aplicación 2: Epsilon Greedy + RecSys



ACTIONS

- COLLABORATIVE FILTERING
- MATRIX FACTORIZATION ALS
- MATRIX FACTORIZATION BPR

Aplicaciones de sistemas de recomendación

- 1. Sistemas recomendadores conversacionales**
- 2. Recomendación basada en grafos**

1. Sistemas recomendadores conversacionales



Sistema recomendador conversacional

¿Qué es un sistema conversacional?

Un sistema recomendador que da **sugerencias personalizadas** a través de diálogos en lenguaje natural con un sistema.

Model: I recommend Pulp Fiction. This is a dark comedy with a great cast.

User: I don't want to watch a comedy right now.

Model: How about Ice Age? It is a very good anime with a lot of action adventure.

User: I don't like anime, but action movie sounds good.

Model: I recommend Mission Impossible. This is by far the best of the action series.


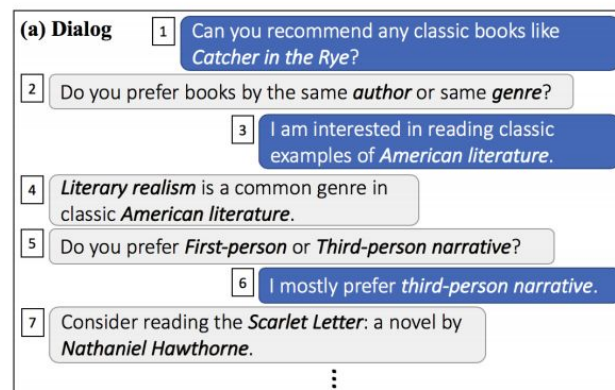
User: Sounds great. Thanks for the recommendation!

Predefined Template

Recommended Item

Generated Explanation

CHEN ET AL, IJCAI 2020



OPENDIAL KG MOON ET AL, ACL 2019



También puede funcionar en lenguaje **escrito** o **hablado**.

CONVERSATIONAL COMMERCE TRANSFORMS CUSTOMER EXPERIENCE

El comercio conversacional se trata de brindar **conveniencia, personalización y apoyo a la toma de decisiones** mientras las personas **están en movimiento**, con atención parcial.



Chris Messina

Head of West Coast Biz Dev @ Republic. Inventor of the hashtag. Product therapist. Previously: Google, Uber, On Deck, YC W'18.




Sistema recomendador conversacional

una forma natural y privada de recibir recomendaciones:

- descubrir las necesidades del usuario mediante diálogos.
- dar orientación en una situación particular.



Sistema recomendador conversacional: arquitectura



Datos de entrenamiento


1. Convertir reviews de productos en una conversación.
2. Amazon mechanical turk - Diálogos entre dos usuarios.
3. Diálogos telefónicos transcritos.

...



Dataset	Dialog Types	Domains	External Knowledge
ConvRec [10]	Rec	Restaurant	N
SAUR [11]	Rec	E-commerce	N
Cookie [24]	Rec	E-commerce	Y
ReDail [13]	Rec, Chitchat	Movie	N
OpendialKG [14]	Rec	Music, Sports	Y
KBRD [15]	Rec	Movie	Y
DuRecDial [21]	Rec, Chitchat, QA	Movie, Music, Restaurant, News, Weather	Y
MGConvRex [23]	Rec, Chitchat, QA	Restaurant	Y

2. Sistemas recomendadores basados en grafos








Una forma natural de representar interacciones en un sistema recomendador es con grafos.



Aprender embeddings
de usuarios e items
(nodos dentro de un
grafo)

A partir de las
interacciones (aristas)

La tarea es predecir
interacciones futuras
entre nodos.



- Cada nodo es un vector de características (embeddings)
- La tarea es actualizar estos vectores para forzarlos a predecir interacciones futuras con otros nodos.

Knowledge graph embedding learning

We have triplets $\langle \mathbf{s}, \mathbf{r}, \mathbf{d} \rangle$ corresponding to E

$$\langle \mathbf{s}, \mathbf{r}^{(i)}, \mathbf{d} \rangle$$

Each element have vectors:

$$(\theta_s, \theta_r^{(i)}, \theta_d)$$

Function f relates $\mathbf{s}$, $\mathbf{r}$ and $\mathbf{d}$

$$f(\theta_s, \theta_r^{(i)}, \theta_d) = \text{sim}(g(\theta_s, \theta_r^{(i)}), g(\theta_d, \theta_r^{(i)}))$$

Objective: Maximize cases where the triple e belongs to E , and to minimize cases when the edge does not exist in the graph.

$$L = \sum_{e \in E} \sum_{e' \in S'_e} \max(f(e) - f(e') + \lambda, 0)$$

Transformation function g encodes the relation between nodes and relations $r(i)$ vectors. e' is an edge that does not exist in the graph.

Knowledge graph embedding learning (relation functions g)

Model	Score function	#Parameters
SE [Bordes <i>et al.</i> , 2011]	$\ \mathbf{M}_r^h \mathbf{h} - \mathbf{M}_r^t \mathbf{t}\ _{\ell_{1/2}}$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{M}_r^h, \mathbf{M}_r^t \in \mathbb{R}^{k_e \times k_e}$	$2k_e n_e + 2k_e^2 n_r$
SME(linear) [Bordes <i>et al.</i> , 2012]	$-(\mathbf{M}_{h_1} \mathbf{e}_h + \mathbf{M}_{h_2} \mathbf{r} + \mathbf{b}_h)^\top (\mathbf{M}_{t_1} \mathbf{e}_t + \mathbf{M}_{t_2} \mathbf{r} + \mathbf{b}_t)$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{M}_r^1, \mathbf{M}_r^2 \in \mathbb{R}^{k_e \times k_e}$	$2k_e n_e + 2k_e^2 n_r$
SME(bilinear) [Bordes <i>et al.</i> , 2012]	$-[(\mathbf{M}_{h_1} \mathbf{e}_h) \otimes (\mathbf{M}_{h_2} \mathbf{r}) + \mathbf{b}_h]^\top [(\mathbf{M}_{t_1} \mathbf{e}_t) \otimes (\mathbf{M}_{t_2} \mathbf{r}) + \mathbf{b}_t]$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{M}_r^1, \mathbf{M}_r^2 \in \mathbb{R}^{k_e \times k_e}$	$2k_e n_e + 2k_e^2 n_r$
TransE [Bordes <i>et al.</i> , 2013]	$\ \mathbf{h} + \mathbf{r} - \mathbf{t}\ _{\ell_{1/2}},$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{r} \in \mathbb{R}^{k_r}$	$k_e n_e + k_r n_r (*k_e = k_r)$
TransH [Wang <i>et al.</i> , 2014]	$\ \mathbf{h}(\mathbf{I} - \mathbf{w}_r^\top \mathbf{w}_t) + \mathbf{r} - \mathbf{t}(\mathbf{I} - \mathbf{w}_r^\top \mathbf{w}_t)\ _{\ell_{1/2}},$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^k, \mathbf{w}_r, \mathbf{r} \in \mathbb{R}^k$	$k_e n_e + 2k_r n_r$
TransR [Lin <i>et al.</i> , 2015]	$\ \mathbf{h} \mathbf{M}_r + \mathbf{r} - \mathbf{t} \mathbf{M}_r\ _{\ell_{1/2}},$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{r} \in \mathbb{R}^{k_r}, \mathbf{M}_r \in \mathbb{R}^{k_e \times k_r}$	$k_e n_e + (k_r + k_r^2) n_r$
TransD [Ji <i>et al.</i> , 2015]	$\ (\mathbf{r}_p \mathbf{h}_p^\top + \mathbf{I}^{k_r \times k_e}) \mathbf{h} + \mathbf{r} - (\mathbf{r}_p \mathbf{t}_p^\top + \mathbf{I}^{k_r \times k_e}) \mathbf{t}\ _{\ell_{1/2}},$ $\mathbf{h}, \mathbf{t}, \mathbf{h}_p, \mathbf{t}_p \in \mathbb{R}^{k_e}, \mathbf{r}, \mathbf{r}_p \in \mathbb{R}^{k_r}$	$4k_e n_e + 2k_r n_r$
TranSparse(<i>separate</i>) [Ji <i>et al.</i> , 2016]	$\ \mathbf{M}_r^1(\theta_r^1) \mathbf{h} + \mathbf{r} - \mathbf{M}_r^2(\theta_r^2) \mathbf{t}\ _{\ell_{1/2}}$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{r} \in \mathbb{R}^{k_r}, \mathbf{M}_r^1(\theta_r^1), \mathbf{M}_r^2(\theta_r^2) \in \mathbb{R}^{*k_r \times k_e}$ $0 \ll \theta_r^1, \theta_r^2 \leq 1$	$2k_e n_e + 2(1 - \theta)(k_e + 1)k_r n_r$ $0 \ll \theta_r^1, \theta_r^2 \leq 1$
GTrans-DW [Tan <i>et al.</i> , 2018]	$\ 1/\sigma \odot [(\alpha \mathbf{h}_e + \beta \mathbf{r}_a \mathbf{h}_a^\top \mathbf{h}_e) + \mathbf{r}_e - (\alpha \mathbf{t}_e + \beta \mathbf{r}_a \mathbf{t}_a^\top \mathbf{t}_e)]\ _{\ell_{1/2}}$ $\mathbf{h}_a, \mathbf{h}_e, \mathbf{t}_a, \mathbf{t}_e \in \mathbb{R}^{k_e}, \mathbf{r}_a, \mathbf{r}_e \in \mathbb{R}^{k_r}, \sigma, \alpha, \beta \in \mathbb{R}$	$k_e n_e + 3k_r n_r (*k_e = k_r)$
GTrans-SW [Tan <i>et al.</i> , 2018]	$\ 1/\sigma \odot [(1 - \alpha_{h,r}) \mathbf{h}_e + \alpha_{h,r} \mathbf{r}_a \mathbf{h}_a^\top \mathbf{h}_e + \mathbf{r}_e - (1 - \alpha_{t,r}) \mathbf{t}_e - \alpha_{t,r} \mathbf{r}_a \mathbf{t}_a^\top \mathbf{t}_e]\ _{\ell_{1/2}}$ $\mathbf{h}_a, \mathbf{h}_e, \mathbf{t}_a, \mathbf{t}_e \in \mathbb{R}^{k_e}, \mathbf{r}_a, \mathbf{r}_e \in \mathbb{R}^{k_r}, \sigma, \alpha, \beta \in \mathbb{R}$	$k_e n_e + 3k_r n_r (*k_e = k_r)$
TransMS	$\ -\tanh(\mathbf{t} \otimes \mathbf{r}) \otimes \mathbf{h} + \mathbf{r} - \tanh(\mathbf{h} \otimes \mathbf{r}) \otimes \mathbf{t} + \alpha \cdot g(\mathbf{h} \otimes \mathbf{t})\ _{\ell_{1/2}},$ $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{r} \in \mathbb{R}^{k_r}, \alpha = \mathbf{r}_{k_r+1} \in \mathbb{R}^1$	$k_e n_e + (k_r + 1) n_r (*k_e = k_r)$

Table 2: Statistics of datasets used in experiments. We mainly compare the models' score functions and their numbers of parameters. n_e and n_r represent the number of entities and relations in knowledge graph respectively. k_e and k_r represent the dimension of entity and relation in the low-dimensional space, $\mathbf{h}, \mathbf{t} \in \mathbb{R}^{k_e}, \mathbf{r} \in \mathbb{R}^{k_r}$. θ_r^1 and θ_r^2 denote the sparse degrees of transfer matrices in TranSparse. α represents one additional dimension for each relation vectors in our model TransMS. For TransE, GTrans and TransMS, $(*k_e = k_r)$ means that k_e is equal to k_r .




Figure 1: Example of HIN, which is built based on the web page for Royal House on Yelp.

Material adicional

Latent space representation images

<https://medium.com/mlearning-ai/latent-space-representation-a-hands-on-tutorial-on-autoencoders-in-tensorflow-57735a1c0f3f>

Artificial Intelligence in Finance

<https://medium.com/mlearning-ai/latent-space-representation-a-hands-on-tutorial-on-autoencoders-in-tensorflow-57735a1c0f3f>

The Two-tower model

<https://www.shaped.ai/blog/the-two-tower-model-for-recommendation-systems-a-deep-dive>

Gracias!

