


Clase 1.2

Conceptos básicos


Teoría de Grafos para Machine Learning

Antonio Ossa Guerra
aaossa@ing.puc.cl


Grafo



Nodos o vértices



Arcos o aristas




Componentes de una red

- **Objetos**: nodos, vértices (N)
- **Interacciones**: arcos, aristas
- **Sistema**: red, grafo

N (conjunto de nodos)

E (conjunto de aristas)

$G(N, E)$ (grafo)



Un grafo puede representar cualquier cosa





Figura: [CS224W: Machine Learning with Graphs \(Iure Leskovec\) @ Stanford](#)

Grafos no dirigidos vs Grafos dirigidos


No dirigidos

- Arcos sin dirección (simétricos)
- Ejemplos: amistad en Facebook



Dirigidos

- Arcos tienen sentido
- Ejemplos: seguir en Twitter (X), citaciones de papers




Grafos heterogéneos

Un grafo heterogéneo se puede definir como $G = (V, E, R, T)$, donde:

- V es el conjunto de nodos
- E son las relaciones entre nodos: (v_1, r, v_2)
- T indica el tipo de nodo: $T(v)$
- R es el conjunto de tipos de relaciones (r es parte de R)

Ejemplo de grafo heterogéneo

- **Nodo:** Migraña
- **Arco:** (fulvestrant, Treats, Breast Neoplasms)
- **Tipo de nodo:** Proteína
- **Tipo de arco:** "Causa"




Grafo bipartito

Un **grafo bipartito** es un grafo cuyos nodos pueden ser divididos en dos conjuntos disjuntos U y V tales que todos los arcos unen un elemento de U con un elemento de V , es decir, U y V son conjuntos independientes.


Ejemplos:

- Autores a papers
- Actores a películas
- Usuarios a películas



Grado de un nodo

El **grado de un vértice/nodo** es el número de aristas incidentes al vértice, básicamente, el **número de arcos que se conectan a un nodo particular**:




Grado promedio:

$$\bar{k} = \langle k \rangle = \frac{1}{N} \sum_{i=1}^N k_i = \frac{2E}{N}$$

Grado de un nodo

En el caso de grafos dirigidos, definimos un **grado de entrada** (in-degree) y un **grado de salida** (out-degree) según la cantidad de arcos que llegan o parten desde el nodo de interés



$$k_C^{in} = 2 \quad k_C^{out} = 1 \quad k_C = 3$$


$$\bar{k} = \frac{E}{N}$$

Grado
promedio

$$\overline{k^{in}} = \overline{k^{out}}$$

Matriz de adyacencia

Dado un grafo, podemos representarlo con una matriz indicando la existencia de arcos entre nodos



$A_{ij} = 1$ si existe un arco de i a j
 $A_{ij} = 0$ en caso contrario

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix} \quad A = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{pmatrix}$$

¿Qué ocurre en el mundo real?

NETWORK	NODES	LINKS	DIRECTED/ UNDIRECTED	N	L	<k>
Internet	Routers	Internet connections	Undirected	192,244	609,066	6.33
WWW	Webpages	Links	Directed	325,729	1,497,134	4.60
Power Grid	Power plants, transformers	Cables	Undirected	4,941	6,594	2.67
Phone Calls	Subscribers	Calls	Directed	36,595	91,826	2.51
Email	Email Addresses	Emails	Directed	57,194	103,731	1.81
Science Collaboration	Scientists	Co-authorship	Undirected	23,133	93,439	8.08
Actor Network	Actors	Co-acting	Undirected	702,388	29,397,908	83.71
Citation Network	Paper	Citations	Directed	449,673	4,689,479	10.43
E. Coli Metabolism	Metabolites	Chemical reactions	Directed	1,039	5,802	5.58
Protein Interactions	Proteins	Binding interactions	Undirected	2,018	2,930	2.90


¿Qué ocurre en el mundo real?

NETWORK	NODES	LINKS	DIRECTED/ UNDIRECTED	N	L	<k>
Internet	Routers	Internet connections	Undirected	192,244	609,066	6.33
WWW	Webpages	Links	Directed	325,729	1,497,134	4.60
Power Grid	Power plants, transformers	Cables	Undirected	4,941	6,594	2.67
Phone Call						2.51
Email						1.81
Science Citations						8.08
Actor Network						83.71
Citation Network	Paper	Citations	Directed	449,673	4,689,479	10.43
E. Coli Metabolism	Metabolites	Chemical reactions	Directed	1,039	5,802	5.58
Protein Interactions	Proteins	Binding interactions	Undirected	2,018	2,930	2.90

Densidad de la matriz de adyacencia (E/N^2):
WWW = 1.51×10^{-5}


En general, son *sparse* (dispersas)

- La matriz de adyacencia se llena de ceros, debido a que el grado promedio de los nodos es mucho menor que el número de nodos
- Existen estructuras de datos que nos ayudan a contener estas grandes matrices en memoria (como `scipy.sparse`)



Atributos de nodos y arcos


- Pesos
ej: número de interacciones
- Ranking
mayor a menor importancia
- Tipo
ej: amigo, familiar, compañero, etc.
- Propiedades dependiendo de la estructura del resto del grafo
ej: número de amigos en común



Más tipos de grafos

Grafo sin pesos (no dirigido)

Ej: amistad, *links*
entre sitios web



$$A_{ij} = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$


$$A_{ii} = 0$$

$$A_{ij} = A_{ji}$$

$$E = \frac{1}{2} \sum_{i,j=1}^N A_{ij} \quad \bar{k} = \frac{2E}{N}$$

Grafo con pesos (no dirigido)

Ej: velocidad
internet,
cantidad de
interacciones



$$A_{ij} = \begin{pmatrix} 0 & 2 & 0.5 & 0 \\ 2 & 0 & 1 & 4 \\ 0.5 & 1 & 0 & 0 \\ 0 & 4 & 0 & 0 \end{pmatrix}$$

$$A_{ii} = 0$$


$$A_{ij} = A_{ji}$$

$$E = \frac{1}{2} \sum_{i,j=1}^N \text{nonzero}(A_{ij}) \quad \bar{k} = \frac{2E}{N}$$

Más tipos de grafos

Grafo con bucles (self-loop)

Ej: proteínas,
links entre sitios
web (auto
referencia)




$$A_{ij} = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix}$$

$$A_{ii} \neq 0 \quad A_{ij} = A_{ji}$$
$$E = \frac{1}{2} \sum_{i,j=1, i \neq j}^N A_{ij} + \sum_{i=1}^N A_{ii}$$

Multigrafo

Ej:
comunicación,
colaboración




$$A_{ij} = \begin{pmatrix} 0 & 2 & 1 & 0 \\ 2 & 0 & 1 & 3 \\ 1 & 1 & 0 & 0 \\ 0 & 3 & 0 & 0 \end{pmatrix}$$

$$A_{ii} = 0 \quad A_{ij} = A_{ji}$$
$$E = \frac{1}{2} \sum_{i,j=1}^N \text{nonzero}(A_{ij}) \quad \bar{k} = \frac{2E}{N}$$


Conectividad en grafos no dirigidos

Un **grafo conexo** (o conectado) es aquel en el que cualquier par de vértices pueden ser unidos con un camino, pasando por arcos existentes




Conectividad en grafos no dirigidos

Un **grafo desconexo o inconexo** está compuesto por dos o más componentes conexas



Conectividad en grafos no dirigidos

La matriz de adyacencia de una red con componentes desconexas puede escribirse en forma de una “matriz por bloques”



Clase 1.2

Conceptos básicos

Teoría de Grafos para Machine Learning

Antonio Ossa Guerra
aaossa@ing.puc.cl